


FusionOne Storage
22.0.7

技术白皮书

文档版本 01
发布日期 2024-01-30



版权所有 © 超聚变数字技术有限公司 2024。保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

商标声明

XFUSION 和其他超聚变商标均为超聚变数字技术有限公司的商标。
本文档提及的其他所有商标或注册商标，由各自的所有人拥有。

注意

本文中，只是为了描述的简洁和方便理解，用“xFusion”指代“xFusion Digital Technologies Co., Ltd.”，这并不代表“xFusion”还可以具备其它含义。基于本文中单独提及或描述的“xFusion”，不能用于“xFusion Digital Technologies Co., Ltd.”之外的理解或表达，超聚变数字技术有限公司也不承担因单独使用“xFusion”所带来的其它任何法律责任。

您购买的产品、服务或特性等应受超聚变数字技术有限公司商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，超聚变数字技术有限公司对本文档内容不做任何明示或默示的声明或保证。

由于产品版本升级或其他原因，本文档内容会不定期进行更新。除非另有约定，本文档仅作为使用指导，本文档中的所有陈述、信息和建议不构成任何明示或暗示的担保。

超聚变数字技术有限公司

地址：河南省郑州市郑东新区龙子湖智慧岛正商博雅广场1号楼9层 邮编：450046

网址：<https://www.xfusion.com>

前言

概述

本文档详细的描述了FusionOne Storage的产品技术知识，从产品功能、应用场景、技术价值等多方面进行介绍，便于读者全面了解产品。

读者对象

本文档主要适用于以下工程师：

- 技术支持工程师
- 存储系统管理员
- 售前工程师

符号约定

在本文中可能出现下列标志，它们所代表的含义如下。

符号	说明
 危险	表示如不避免则将会导致死亡或严重伤害的具有高等级风险的危害。
 警告	表示如不避免则可能导致死亡或严重伤害的具有中等级风险的危害。
 注意	表示如不避免则可能导致轻微或中度伤害的具有低等级风险的危害。
 须知	用于传递设备或环境安全警示信息。如不避免则可能会导致设备损坏、数据丢失、设备性能降低或其它不可预知的结果。 “须知”不涉及人身伤害。
 说明	对正文中重点信息的补充说明。 “说明”不是安全警示信息，不涉及人身、设备及环境伤害信息。

修改记录

文档版本	发布日期	修改说明
01	2024-01-30	第一次正式发布。

目录

前言.....ii

1 概述.....1

2 产品价值.....2

3 产品架构.....3

4 组网规划.....5

4.1 概述.....5

4.2 FusionOne Storage 2U 24 盘位 NVMe SSD 性能型节点（存储业务和管理共享网络，存储集群独立组网）.....6

4.3 FusionOne Storage 2U 16 盘位 NVMe SSD 性能型节点（存储业务独立组网，存储集群独立组网，存储管理独立组网）.....8

4.4 FusionOne Storage 2U/4U HDD 容量型节点（存储业务独立组网，存储集群独立组网，存储管理独立组网）.....11

4.5 交换机接口规划（10GE 存储业务网络+10GE 存储集群网络）.....13

4.6 交换机接口规划（25GE 存储业务网络+25GE 存储集群网络）.....15

5 存储硬件.....17

5.1 FusionOne Storage 2U NVMe SSD 性能型节点.....18

5.2 FusionOne Storage 2U SATA HDD 容量型节点.....19

5.3 FusionOne Storage 4U SATA HDD 容量型节点.....20

5.4 FusionOne Storage 2U SATA HDD 容量型节点(昆仑 2280).....21

5.5 FusionOne Storage 4U SATA HDD 容量型节点(昆仑 5280).....22

6 块存储特性.....23

6.1 快照.....23

6.2 LUN Masking.....25

6.3 快速离线.....25

6.4 卷级 QoS.....25

6.5 扩容.....26

6.6 异步复制.....27

6.7 延展集群.....28

6.8 精简配置.....29

6.9 卷克隆.....29

6.10 节点冗余设计.....29

6.11 卷独占.....29

7 NAS 存储特性	30
7.1 NAS 存储高可用技术	30
7.2 NAS 存储接口	30
7.3 配额	31
8 对象存储特性	33
8.1 对象存储负载均衡及高可用	33
8.2 小文件在线合并	34
8.3 对象多版本及 CDP 技术	35
8.4 对象生命周期管理	37
8.5 授权管理	38
8.6 对象压缩	39
8.7 对象重删	41
8.8 对象预览	43
8.9 对象检索	43
9 文件存储特性	44
9.1 技术背景	44
9.2 技术原理	44
9.3 技术特点	46
9.4 客户价值	47
10 可靠性	48
10.1 软件可靠性	48
10.1.1 快速 IO 重试	48
10.1.2 亚健康健康管理	48
10.1.2.1 节点亚健康健康管理	48
10.1.2.2 硬盘亚健康健康管理	49
10.1.2.3 网络亚健康健康管理	49
10.1.3 硬盘错误在线读修复技术	49
10.1.4 恢复 QoS 控制	50
10.1.5 数据可靠性	51
10.1.5.1 对象 WORM	51
10.1.5.2 数据保护	52
10.1.5.3 多硬盘池	52
10.1.5.4 多副本	54
10.1.5.5 Erasure Code	54
10.1.5.6 数据一致性	57
10.1.5.7 掉电保护	57
10.1.5.8 快速数据重建	57
10.1.5.9 数据恢复	57
10.2 硬件可靠性	58
11 弹性伸缩	60
11.1 弹性扩展	60

11.2 DHT 分布式哈希算法.....	61
11.3 数据副本在线转换.....	62
12 高性能.....	63
12.1 负载均衡.....	63
12.2 智能缓存.....	64
12.2.1 数据类型感知.....	64
12.2.2 多级缓存加速.....	65
12.2.3 分布式缓存.....	65
12.2.4 读缓存.....	66
12.2.5 写缓存.....	66
12.2.6 缓存资源回收.....	66
12.2.7 大块数据透传.....	66
13 安全性.....	67
13.1 设备安全.....	67
13.1.1 操作系统安全性（自研 FusionOS 22）.....	67
13.1.2 硬件安全.....	69
13.2 网络安全.....	70
13.3 管理&业务安全.....	71
13.3.1 存储管理系统安全.....	71
13.3.2 数据服务安全.....	73
13.3.3 数据存储安全.....	73
14 开放兼容.....	75
14.1 存储协议兼容.....	75
14.2 虚拟化平台兼容.....	75
14.3 OpenStack 云管平台.....	75
14.4 非 OpenStack 云管平台.....	76
14.5 综合网管平台兼容性.....	76
15 术语.....	77

1 概述

随着5G、工业互联网、云计算、大数据和人工智能等新技术的兴起与普及，企业新兴应用层出不穷，数据快速增长，业务加速创新对于存储能力的快速迭代提出了更高要求。在证券、银行、大企业，紧握互联网、特别是移动互联网崛起带来的机遇，同时也不得不迎接由此带来的挑战：

- 新业务需要数小时内快速上线。
- 快速、精准的用户需求分析、行为分析等。

在政府、制造、运营商等行业中，与金融、大企业面临相似的问题。随着新兴业务的激增、业务数据呈现几何倍数的快速增长，使得数据中心存储系统开始面临新的挑战：

- 新建存储系统周期长与新兴业务快速上线间的矛盾。
- 系统庞大，管理复杂，运维人员压力巨大。
- 存储性能无法满足越来越多的数据并行处理的应用需求。
- 客户需求分析、业务数据分析与决策推荐等需求，导致对大数据、云计算等新技术应用的需求。

FusionOne Storage应运而生，对存储系统做出如下定义：

- 存储应该是快速便捷的，资源弹性伸缩、快速部署、按需配置、按需获取，支撑新兴业务快速上线。
- 面对数据中心结构化数据、非结构化数据等复杂的业务类型，能按需提供丰富的访问接入支持。
- 可进行快速横向扩展，扩展方式要快速、便捷。
- 提供极致性能，满足业务数据处理需求。
- 满足业务功能诉求的同时，TCO(Total Cost of Ownership)要相对最低。

FusionOne Storage是一款将本地存储资源组织起来构建全分布式存储池，实现向上层应用提供分布式块存储服务、对象存储服务、文件存储服务的一款企业级的大规模横向扩展的分布式存储产品。提供高效率、高可用和极致扩展的智能分布式存储，满足云和AI时代复杂的业务负载对存储提出的更高的性能、容量和扩展性需求，广泛适用于金融、运营商、政府公共事业等行业云资源池、关键业务数据库、虚拟化、内容存储和备份归档等场景。

2 产品价值

全分布式架构，按需使用

FusionOne Storage通过分布式技术将HDD、SSD等存储资源组织成分布式存储资源池，为上层应用和客户端提供标准接口，消除资源组织模式形成资源孤岛、硬件资源利用不均、整体资源浪费等问题。

- 块存储服务：FusionOne Storage通过存储虚拟化技术创建SAN存储，提供RBD、iSCSI，支持广泛的虚拟化平台及数据库应用，提供高性能与高扩展能力，满足虚拟化、备份、视频监控、大数据等场景的存储需求。
- 对象存储服务：提供Amazon S3等标准API，支持主流云计算生态，满足内容存储、云备份、云归档及公有云存储服务运营场景需求。
- 文件存储服务：提供NFS、CIFS等标准接口，以卓越性能、大规模横向扩展能力和超大规模分布式文件系统为用户提供非结构化数据共享存储资源，应用于视频、音频、高性能计算、视频监控等多业务场景。

弹性高效

FusionOne Storage采用全分布式架构，支持通过横向扩展硬件节点线性增加整系统容量与性能，资源供给可预期，无需复杂的资源需求规划；系统可轻松扩展至数千节点及EB级容量，满足您的云业务规模扩张。

提供自动负载均衡策略，数据与元数据均匀分布于各节点，消除元数据访问瓶颈，保障规模扩展场景下的系统性能。

企业级可靠

FusionOne Storage基于块存储、对象存储、文件存储提供满足应用场景需求的丰富企业级特性。快照、远程复制、EC、副本、对象CDP、对象生命周期管理等助您轻松构建解决方案级数据保护机制；精简配置、分级存储等可助您构建更合理的硬件资源利用方案；多租户功能助您建立企业内部云存储资源的更灵活、有效分配策略。


自动化服务&运维

FusionOne Storage存储管理系统可以完成业务配置，并提供告警、拓扑、性能报表等丰富的硬件平台监控与管理功能。自动化、完善的管理功能，将数据中心运维人员从繁琐复杂的软硬件资源管理中解放出来，支撑业务上线时间由10天缩短至0.5~1小时，极大缩短TTM。

3 产品架构

FusionOne Storage采用业界先进的全分布式和Share Nothing架构设计理念，采用基于策略的分布式哈希表数据路由算法，通过计算就能直接寻址到数据所在的存储节点，无需查找元数据节点，大大缩短了数据IO访问路径，提升了系统性能。

同时，整个系统也无集中管理和控制节点，每一个数据节点都有能力承担任何数据节点的功能，节点之间通过内部高效的分布式协议完成相互协作和通信。这种去中心化、无状态的全分布式数据处理架构是系统能实现水平、线性扩展能力的关键，有力保证了整个系统无单点故障、无性能瓶颈。这样的设计使得用户首次购买或者扩容时，不需要考虑独立元数据节点或独立网管节点等问题，只需根据实际需求计算出需要的节点数即可。



FusionOne Storage对外提供块、对象和文件存储服务，可以支持各种数据库负载、虚拟化应用和云原生应用，也可以应用于生产业务系统、数据管理系统、数据分析系统，满足关键业务和形态各异的众多应用的不同存储需求。

系统功能架构

FusionOne Storage分布式存储必须基于全分布式存储架构，通过软件层面的全分布式架构和数据冗余技术，来达到高可伸缩性和高可用性，性能、容量随节点数增加而线性增加。单集群最高可支持扩展至4096个节点。支持在单个集群内按磁盘维度划分多个硬盘池，支持图形化界面划分存储资源池。



- 存储接口层：提供标准iSCSI、SCSI协议的块设备接口或应用态块接口向应用提供卷设备访问功能。支持S3接口，实现文件的HTTP/HTTPS形式访问，也可以利用不同语言的SDK简化S3接口的访问。同时支持NFS、CIFS等传统文件访问接口，并能够与S3接口互通。
- 存储服务层：提供各种存储高级特性，如块存储快照、精简配置、SSD加速、硬件感知框架，对象存储的生命周期、用户配额、负载均衡等功能，文件存储的共享配置、AD域、跨协议等功能。
- 存储引擎层：FusionOne Storage基本功能，包括集群状态管理、分布式数据路由、强一致性复制协议，及在节点故障时集群故障自愈与并行数据重建子系统等。
- 存储硬件层：支持SAS、SATA、NVMe。为了对硬件进行控制和故障管理，实现了磁盘控制卡管理和磁盘错误管理功能。
- 存储管理层：实现FusionOne Storage的可视化安装部署、可视化配置、在线升级、软硬件系统监控、告警日志等运维管理功能，为用户提供Web GUI管理界面和命令行管理系统。面向运维、运营、审计、业务等IT角色提供丰富的企业级特性，提供简单、易用、内容丰富的图形化管理界面，包括仪表盘、硬件监控、多数据中心管理、性能指标统计、软硬件告警及展示等功能特性，支持升级、扩容、配置等变更操作功能特性。对运营、业务、审计方提供面向角色的业务访问精细统计报表，运营数据等。

4 组网规划

4.1 概述

4.2 FusionOne Storage 2U 24盘位 NVMe SSD 性能型节点（存储业务和管理共享网络，存储集群独立组网）

4.3 FusionOne Storage 2U 16盘位 NVMe SSD 性能型节点（存储业务独立组网，存储集群独立组网，存储管理独立组网）

4.4 FusionOne Storage 2U/4U HDD 容量型节点（存储业务独立组网，存储集群独立组网，存储管理独立组网）

4.5 交换机接口规划（10GE 存储业务网络+10GE 存储集群网络）


4.6 交换机接口规划（25GE 存储业务网络+25GE 存储集群网络）

4.1 概述

网络介绍

FusionOne Storage分布式存储集群系统网络示意如图4-1。

图 4-1 FusionOne Storage 分布式存储网络示意



- 存储业务网络
用于存储节点和计算节点（业务主机）之间的通信，支持iSCSI/RBD/NFS/CIFS/S3对象接口协议。
- 管理网络
用于存储集群系统的管理维护。
- 存储集群网络
存储集群系统内部存储节点间的通信网络。

说明

存储业务网络和管理网络可以共享网络，此时存储业务网络和管理网络使用同一张物理网卡。

基本概念


- 管理节点：负责分布式存储系统的配置、监控、告警、日志等日常操作维护功能
- 存储节点：提供存储资源的服务器
- 计算节点：运行业务应用系统的服务器

4.2 FusionOne Storage 2U 24 盘位 NVMe SSD 性能型节点（存储业务和管理共享网络，存储集群独立组网）

组网方案介绍

物理组网如图4-2所示（物理组网中存储业务网络和管理网络共用一张物理网卡，网卡上的每个网口配置2个不同的IP分别对应存储业务网络和管理网络）。

图 4-2 物理组网



网络要求如下表所示。

节点类型	网络要求	IP地址规划
管理节点	管理节点既可以使用虚拟机也可以使用物理服务器。	可访问存储设备管理网络。
计算节点	业务网络： 计算节点（业务主机）与存储业务网络之间的连接。建议采用bond网口模式进行网口聚合，提升网络冗余可靠性。 网卡和网络类型： TCP/IP：支持10GE/25GE网络，至少需要2*10GE网口或2*25GE网口组网。建议采用bond网口模式进行网口聚合，支持bond1和bond4绑定模式，推荐配置bond4。	配置计算节点业务网络IP，连接存储业务网络。
存储节点	管理网络： 管理网口可支持单网口或者双网口。	配置管理网络IP接入管理网络。管理网络与存储业务网络共用网卡，2个网络平面间通过VLAN隔离。
	存储业务网络： 存储节点与计算节点（业务主机）之间的连接。存储业务网络采用bond网口模式（bond4）进行网口聚合，提升网络冗余可靠性。 注意： 针对2U 24盘位NVMe SSD典型机型，由于单存储服务器节点只能部署2张物理网卡，所以存储业务网络和管理网络共用1张物理网卡，存储集群网络独占1张物理网卡。	配置存储业务网络IP与存储管理网络共用物理网卡，2个网络平面间通过VLAN隔离。 说明：如果计划后续进行扩容，建议提前为待扩容节点预留存储业务网络IP地址。
	存储集群网络： 存储网络网卡和网络类型： TCP/IP：采用bond网口模式进行网口聚合，支持bond1和bond4绑定模式，推荐配置bond4。支持10GE/25GE，至少需要2*10GE网口或2*25GE网口组网。	配置存储集群网络IP，进行存储节点间互联。 说明：如果计划后续进行扩容，建议提前为待扩容节点预留存储网络IP地址。
存储业务交换机	● 提供1个管理网口，接入到管理网络。 ● 推荐2台存储交换机之间的互联配置为M-LAG。	配置1个管理网络IP。
存储集群交换机	● 提供1个管理网口，接入到管理网络。 ● 推荐2台存储交换机之间的互联配置为M-LAG。	配置1个管理网络IP。

计算节点接口规划

计算节点配置由客户决定，根据存储业务网络类型，连接存储业务网络的计算节点网卡通常配置2*10GE或2*25GE网口。

当存储业务网络采用10GE/25GE网络时，节点可配置1张2口10GE/25GE网卡，计算节点接口使用说明如下表所示。

表 4-1 接口使用说明

接口说明	接口类型	接入网络	说明
计算节点连接存储业务网络的接口	10GE/25GE接口	接入存储业务网络	连接到存储业务交换机。 2个网口组成逻辑上的bond。

存储节点接口规划


接口说明	接口类型	接入网络	说明
存储节点上连接业务主机的网络接口	10GE/25GE接口	存储业务网络	连接到存储业务交换机， 2个网口组成逻辑上的bond。
存储节点间进行互联的网络接口	10GE/25GE接口	存储集群网络	连接到存储集群交换机， 2个网口组成逻辑上的bond。
存储节点接入管理网络的网络接口	10GE/25GE接口	管理网络	与存储业务网络共用物理网口，2个网络平面间通过VLAN隔离。 连接到管理交换机。

4.3 FusionOne Storage 2U 16 盘位 NVMe SSD 性能型节点（存储业务独立组网，存储集群独立组网，存储管理独立组网）

组网方案介绍

物理组网如图4-3所示

图 4-3 物理组网



网络要求如下表所示。

节点类型	网络要求	IP地址规划
管理节点	管理节点既可以使用虚拟机环境也可以使用物理服务器。	可访问存储设备管理网络。
计算节点	业务网络： 计算节点（业务主机）与存储节点业务网络之间的连接。建议采用bond网口模式进行网口聚合，提升网络冗余可靠性。 网卡和网络类型： TCP/IP：建议采用bond网口模式进行网口聚合，支持bond1和bond4绑定模式，推荐配置bond4。支持10GE/25GE，至少需要2*10GE网口或2*25GE网口组网。	配置计算节点业务网络IP，连接存储业务网络。
存储节点	管理网络： 管理网口支持单网口或者双网口。	配置管理网络IP接入管理网络。
	存储业务网络： 存储节点与计算节点（业务主机）之间的连接。存储业务网络采用bond网口模式（bond4）进行网口聚合，提升网络冗余可靠性。	配置存储业务网络IP。 说明：如果计划后续进行扩容，建议提前为待扩容节点预留存储业务网络IP地址。

节点类型	网络要求	IP地址规划
	存储集群网络： 存储网络网卡和网络类型： TCP/IP：支持bond1和bond4绑定模式，推荐配置bond4。支持10GE/25GE，至少需要2*10GE网口或2*25GE网口组网。	配置存储集群网络IP。 说明：如果计划后续进行扩容，建议提前为待扩容节点预留存储集群网络IP地址。
存储业务交换机	- 提供1个管理网口，接入到管理网络。 - 推荐2台存储交换机之间的互联配置为M-LAG。	配置1个管理网络IP。
存储集群交换机	- 提供1个管理网口，接入到管理网络。 - 推荐2台存储交换机之间的互联配置为M-LAG。	配置1个管理网络IP。

计算节点接口规划

计算节点配置由客户决定，根据存储业务网络类型，连接存储业务网络的计算节点网卡通常配置2*10GE或2*25GE网口。

当存储业务网络采用10GE/25GE网络时，节点可配置1张2口10GE/25GE网卡，计算节点接口使用说明如下表所示。

表 4-2 接口使用说明

接口说明	接口类型	接入网络	说明
计算节点连接存储业务网络的接口	10GE/25GE接口	接入存储业务网络	连接到存储业务交换机。 2个网口组成逻辑上的bond。

存储节点接口规划


接口说明	接口类型	接入网络	说明
存储节点上连接业务主机的网络接口	10GE/25GE接口	存储业务网络	连接到存储业务交换机。 2个网口组成逻辑上的bond。
存储节点间进行互联的网络接口	10GE/25GE接口	存储集群网络	连接到存储集群交换机。 2个网口组成逻辑上的bond。
存储节点接入管理网络的网络接口	GE接口	管理网络	连接到管理交换机。

4.4 FusionOne Storage 2U/4U HDD 容量型节点（存储业务独立组网，存储集群独立组网，存储管理独立组网）

组网方案介绍

物理组网如图4-4所示

图 4-4 物理组网



网络要求如下表所示。

节点类型	网络要求	IP地址规划
管理节点	管理节点既可以使用虚拟机环境也可以使用物理服务器。	可访问存储设备管理网络。
计算节点	业务网络： 计算节点（业务主机）与存储节点业务网络之间的连接。建议采用bond网口模式进行网口聚合，提升网络冗余可靠性。 网卡和网络类型： TCP/IP：建议采用bond网口模式进行网口聚合，支持bond1和bond4绑定模式，推荐配置bond4。支持10GE/25GE，至少需要2*10GE网口或2*25GE网口组网。	配置计算节点业务网络IP，连接存储业务网络。
存储节点	管理网络： 管理网口支持单网口或者双网口。	配置管理网络IP接入管理网络。

节点类型	网络要求	IP地址规划
	存储业务网络： 存储节点与计算节点（业务主机）之间的连接。存储业务网络采用bond网口模式（bond4）进行网口聚合，提升网络冗余可靠性。	配置存储业务网络IP。 说明：如果计划后续进行扩容，建议提前为待扩容节点预留存储业务网络IP地址。
	存储集群网络： 存储网络网卡和网络类型： TCP/IP：支持bond1和bond4绑定模式，推荐配置bond4。支持10GE/25GE，至少需要2*10GE网口或2*25GE网口组网。	配置存储集群网络IP。 说明：如果计划后续进行扩容，建议提前为待扩容节点预留存储集群网络IP地址。
存储业务交换机	- 提供1个管理网口，接入到管理网络。 - 推荐2台存储交换机之间的互联配置为M-LAG。	配置1个管理网络IP。
存储集群交换机	- 提供1个管理网口，接入到管理网络。 - 推荐2台存储交换机之间的互联配置为M-LAG。	配置1个管理网络IP。

计算节点接口规划

计算节点配置由客户决定，根据存储业务网络类型，连接存储业务网络的计算节点网卡通常配置2*10GE或2*25GE网口。

当存储业务网络采用10GE/25GE网络时，节点可配置1张2口10GE/25GE网卡，计算节点接口使用说明如下表所示。

表 4-3 接口使用说明

接口说明	接口类型	接入网络	说明
计算节点连接存储业务网络的接口	10GE/25GE接口	接入存储业务网络	连接到存储业务交换机。 2个网口组成逻辑上的bond。

存储节点接口规划

接口说明	接口类型	接入网络	说明
存储节点上连接业务主机的网络接口	10GE/25GE接口	存储业务网络	连接到存储业务交换机。 2个网口组成逻辑上的bond。
存储节点间进行互联的网络接口	10GE/25GE接口	存储集群网络	连接到存储集群交换机。 2个网口组成逻辑上的bond。
存储节点接入管理网络的网络接口	GE接口	管理网络	连接到管理交换机。


4.5 交换机接口规划（10GE 存储业务网络+10GE 存储集群网络）

以部署2个计算节点（业务主机）和4个存储节点为例介绍交换机的接口规划。
默认存储业务网络和存储集群网络均独立使用交换机。

存储业务交换机和存储集群交换机接口规划

存储业务交换机规划示例（以配置48个10GE SFP+接口，6个100GE QSFP28接口的交换机为例）如下图所示。


图 4-5 交换机各接口说明



接口	说明
节点接口	每台交换机使用6个10GE接口顺序连接到计算节点和存储节点。
M-LAG接口	每台交换机分别使用2个100GE接口，推荐配置成M-LAG。
汇聚接口	每台交换机提供4个汇聚接口，3号端口和4号端口连接1台汇聚交换机，5号端口和6号端口连接另外1台汇聚交换机。 说明 当存储节点数≤40时，无需使用汇聚交换机，汇聚接口预留。
预留接口	扩容备用端口。

存储集群交换机接口规划示例（以配置48个10GE SFP+接口，6个100GE QSFP28接口的交换机为例）如下图所示。

图 4-6 交换机各接口说明



接口	说明
节点接口	每台交换机使用4个10GE接口顺序连接到存储节点。
M-LAG接口	每台交换机分别使用2个100GE接口，推荐配置成M-LAG。
汇聚接口	每台交换机提供4个汇聚接口，3号端口和4号端口连接1台汇聚交换机，5号端口和6号端口连接另外1台汇聚交换机。 说明 当存储节点数≤40时，无需使用汇聚交换机，汇聚接口预留。
预留接口	扩容备用端口。

4.6 交换机接口规划（ 25GE 存储业务网络+25GE 存储集群网络 ）


以部署2个计算节点（业务主机）和4个存储节点为例介绍交换机的接口规划。

默认存储业务交换机和存储集群交换机均独立使用交换机。

存储业务交换机和存储集群交换机接口规划

存储业务交换机接口规划示例（以配置48个25GE SFP28 接口，8个100GE QSFP28 接口的交换机为例）如下图所示。


图 4-7 交换机各接口说明



接口	说明
节点接口	每台交换机使用6个25GE接口顺序连接到计算节点和存储节点。
M-LAG接口	每台交换机分别使用2个100GE接口，推荐配置成M-LAG。
汇聚接口	每台交换机提供6个汇聚接口，3号端口、4号端口和5号端口连接1台汇聚交换机，6号端口、7号端口和8号端口连接另外1台汇聚交换机。 说明 当存储节点数≤40时，无需使用汇聚交换机，汇聚接口预留。
预留接口	扩容备用端口。

存储集群交换机接口规划示例（以配置48个25GE SFP28 接口，8个100GE QSFP28 接口的交换机为例）如下图所示。

图 4-8 交换机各接口说明



接口	说明
节点接口	每台交换机使用4个25GE接口顺序连接到存储节点。
M-LAG接口	每台交换机分别使用2个100GE接口，推荐配置成M-LAG。
汇聚接口	每台交换机提供6个汇聚接口，3号端口、4号端口和5号端口连接1台汇聚交换机，6号端口、7号端口和8号端口连接另外1台汇聚交换机。 说明 当存储节点数≤40时，无需使用汇聚交换机，汇聚接口预留。
预留接口	扩容备用端口。

5 存储硬件

FusionOne Storage新建场景节点至少3节点起配。节点提供两种主存类型：混合存储和全闪存。其中混合存储采用SATA HDD做主存，NVMe SSD做缓存，缓存建议选用3DWPD或者以上的NVMe SSD。主存类型为全闪存时（当前配置NVMe SSD做主存），此时不配置缓存。

- 单集群支持3～4096个节点，推荐不超过128个节点；
- 单集群支持最大24576块盘，推荐不超过4608块盘；
- 单硬盘池支持最大4608块盘，推荐不超过1536块盘；
- 单节点主存盘要求至少4块盘，推荐不少于8块盘；
- 单集群支持最大1EB，推荐不超过72PB。


节点名称	FusionOne Storage 2U NVMe SSD性能型节点	FusionOne Storage 2U SATA HDD 容量型节点	FusionOne Storage 4U SATA HDD容量型节点
节点类型	全闪	混配	混配
服务器	2288H V6 (24*NVMe)	2288H V6 (12*3.5 SATA)	5288 V6 (36*3.5 SATA)
CPU	IceLake-SP CPU* (最低主频2.1GHz，默认推荐16C，可选12-26C)	IceLake-SP CPU (最低主频2.1GHz，默认推荐12C，可选12-20C)	IceLake-SP CPU (最低主频2.1GHz，默认推荐12C，可选12-20C)
内存	DDR4 RDIMM (192G起配)	DDR4 RDIMM (128G起配)	DDR4 RDIMM (256G起配)
系统盘	2*SAS HDD	2*SAS HDD	2*SAS HDD
Cache	-	1~4*1.6T/3.2T/6.4 NVMe SSD	1~4*1.6T/3.2T/6.4 NVMe SSD
主存	2.5" NVMe SSD	3.5" SATA HDD	3.5" SATA HDD
业务网络	10GE/25GE	10GE/25GE	10GE/25GE

- 5.1 FusionOne Storage 2U NVMe SSD 性能型节点
- 5.2 FusionOne Storage 2U SATA HDD 容量型节点
- 5.3 FusionOne Storage 4U SATA HDD 容量型节点
- 5.4 FusionOne Storage 2U SATA HDD 容量型节点(昆仑2280)
- 5.5 FusionOne Storage 4U SATA HDD 容量型节点(昆仑5280)

5.1 FusionOne Storage 2U NVMe SSD 性能型节点


FusionOne Storage 2U NVMe SSD性能型节点主要用于数据库、虚拟化等高IOPS、低时延的高性能场景。

图 5-1 FusionOne Storage 2U NVMe SSD 性能型节点 1 (16 NVMe)



形态	2U2P机架服务器
处理器	2 个Intel Xeon Icelake Processors (43、53、63、83系列)
内存插槽	32个DDR4 DIMM插槽
硬盘数量	16个2.5英寸NVMe SSD硬盘 4个2.5英寸SAS/SATA硬盘
RAID支持	支持RAID1
OCP网卡	支持GE\10GE\25GE
PCIe扩展	支持1个RAID控制扣卡专用的PCIe扩展槽位，2个OCP 3.0网卡专用槽位，2个标准的PCIe扩展槽位。 说明 由于系统盘、缓存盘占用，具体可用的插槽以实际配置的为准。

图 5-2 FusionOne Storage 2U NVMe SSD 性能型节点 2 (24NVMe)




形态	2U2P机架服务器
处理器	2 个Intel Xeon Icelake Processors (43、53、63、83系列)
内存插槽	32个DDR4 DIMM插槽
硬盘数量	24个2.5英寸NVMe SSD硬盘 或 25个2.5英寸SATA SSD硬盘 2个2.5英寸SAS/SATA硬盘
RAID支持	支持RAID1
OCP网卡	支持GE\10GE\25GE
PCIe扩展	24个2.5英寸NVMe SSD机型：支持1个RAID控制扣卡专用的PCIe扩展槽位，2个OCP 3.0网卡专用的FLEX IO扩展槽位。 25个2.5英寸SATA SSD机型：支持1个RAID控制扣卡专用的PCIe扩展槽位，2个OCP 3.0网卡专用的FLEX IO扩展槽位，8个标准的PCIe扩展槽位。 说明 由于系统盘、缓存盘占用，具体可用的插槽以实际配置的为准。

5.2 FusionOne Storage 2U SATA HDD 容量型节点

FusionOne Storage 2U SATA HDD 容量型节点主要用于视频监控、大数据、备份等大容量存储资源池场景。

图 5-3 FusionOne Storage 2U SATA HDD 容量型节点



形态	2U2P机架服务器
处理器	2个Intel Xeon Icelake Processors (43、53、63、83系列)
内存插槽	32个DDR4 DIMM插槽
硬盘数量	12个3.5英寸SAS/SATA硬盘 2个2.5英寸SAS/SATA硬盘 4个NVMe SSD盘

RAID支持	支持RAID1
OCP网卡	支持GE\10GE\25GE
PCIe扩展	服务器后面板配置硬盘模组/PCIe Riser模组 机型：支持1个RAID控制扣卡专用的PCIe扩展槽位，2个OCP 3.0网卡专用槽位，4个标准的PCIe扩展槽位。 说明 由于系统盘、缓存盘占用，具体可用的插槽以实际配置的为准。

5.3 FusionOne Storage 4U SATA HDD 容量型节点

FusionOne Storage 4U SATA HDD容量型节点，主要用于视频监控、大数据、备份等大容量存储资源池场景。

图 5-4 FusionOne Storage 4U SATA HDD 容量型节点




形态	2U2P机架服务器
处理器	2个Intel Xeon Icelake Processors (43、53、63、83系列)
内存插槽	32个DDR4 DIMM插槽
硬盘数量	36个3.5英寸SAS/SATA硬盘 2个2.5英寸SAS/SATA硬盘 4个NVMe SSD盘
RAID支持	支持RAID1
OCP网卡	支持GE\10GE\25GE

PCIe扩展	服务器后面板配置硬盘模组/PCIe Riser模组机型：支持1个RAID控制扣卡专用的PCIe扩展槽位，2个OCP 3.0网卡专用槽位，4个标准的PCIe扩展槽位。 说明 由于系统盘、缓存盘占用，具体可用的插槽以实际配置的为准。
--------	---

5.4 FusionOne Storage 2U SATA HDD 容量型节点(昆仑2280)

FusionOne Storage 2U SATA HDD昆仑2280节点，主要用于信创场景。



形态	2U2P机架服务器
处理器	2 个鲲鹏920处理器
内存插槽	配置鲲鹏920 5220、3210、5225F和5221K处理器时 最多支持16个DDR4 DIMM插槽 配置鲲鹏920 5250、7260、7265F和5255F处理器时 最多支持32个DDR4 DIMM插槽
硬盘数量	12个3.5英寸SAS/SATA硬盘 2个2.5英寸SAS/SATA硬盘 4个NVMe SSD盘
RAID支持	支持RAID1
OCP网卡	支持GE\10GE\25GE
PCIe扩展	服务器后面板配置硬盘模组/PCIe Riser模组机型：支持2个OCP 3.0网卡专用槽位，4个标准的PCIe扩展槽位。 说明 具体可用的插槽以实际配置的为准。

5.5 FusionOne Storage 4U SATA HDD 容量型节点(昆仑5280)

FusionOne Storage 4U SATA HDD昆仑5280节点，主要用于信创场景。



形态	2U2P机架服务器
处理器	2 个鲲鹏920处理器
内存插槽	配置鲲鹏920 5220、3210和5221K处理器时，最多支持16个DDR4内存插槽 配配置鲲鹏920 5250、7260、5251K和7261K处理器时，最多支持32个DDR4内存插槽
硬盘数量	36个3.5英寸SAS/SATA硬盘 2个2.5英寸SAS/SATA硬盘 4个NVMe SSD盘
RAID支持	支持RAID1
OCP网卡	支持GE\10GE\25GE
PCIe扩展	服务器后面板配置硬盘模组/PCIe Riser模组机型：支持2个OCP 3.0网卡专用槽位，4个标准的PCIe扩展槽位。 说明 具体可用的插槽以实际配置的为准。

6 块存储特性

- 6.1 快照
- 6.2 LUN Masking
- 6.3 快速离线
- 6.4 卷级QoS
- 6.5 扩容
- 6.6 异步复制
- 6.7 延展集群
- 6.8 精简配置
- 6.9 卷克隆
- 6.10 节点冗余设计
- 6.11 卷独占

6.1 快照


FusionOne Storage提供了快照机制，将用户的卷数据在某个时间点的状态保存下来，后续可以作为导出数据、恢复数据之用。

FusionOne Storage快照数据在存储时采用 ROW（Redirect-On-Write）机制，快照对主机业务性能影响小于5%。

秒级快照

FusionOne Storage快照采用ROW（Redirect-On-Write）机制，做快照时生成对应快照数据块链接指向对应数据。当有数据写入时，把对应数据写入另外一个位置，然后修改原卷数据块链接到新位置。ROW写的时候性能基本没有损耗，只是修改指针链接，实现效率很高，不会引起原卷性能下降。通过一次查找操作即可判断是否做过快照，以及最新快照的存储位置，保证业务效率。


图 6-1 快照生成示意图



快照回滚

快照回滚操作在ROW机制中，只需要将当前数据块链接重新指回快照数据即可，回滚速度很快，用户可以短时间内将任何一个存储卷回滚到任何一个时间点的快照。回滚后当前数据不可恢复。


图 6-2 快照回滚示意图



快照删除

快照删除操作在ROW机制中，只需要删除对应快照的链接，相应数据块如果没有其他资源（原卷、快照、克隆卷等）引用才可清除，用户可以删除任何一个时间点的快照，而不影响后续快照，方便快照管理。

图 6-3 快照删除示意图



FusionOne Storage提供了秒级快照机制，将用户的逻辑卷数据在某个时间点的状态保存下来，作为备份恢复数据之用。单卷最大快照个数可以达到256，完全满足正常需求。

6.2 LUN Masking

FusionOne Storage通过LUN Masking功能将各个硬盘池和逻辑池的LUN资源隔离开，确保未授权的用户无法扫描到指定的LUN。

6.3 快速离线

FusionOne Storage提供非常强大的数据保护机制，当集群中有节点或者磁盘故障时，存储管理系统会及时将其踢出集群，并可根据业务需求设定重构和均衡时间，既减小对在线业务的性能影响，也可降低数据安全风险，同时兼顾了存储的性能和安全性。

6.4 卷级 QoS

FusionOne Storage块存储QoS提供了对卷的IOPS、带宽进行精细化控制，当卷的需求超出了基准IOPS或带宽时，允许在一定时间内使用超出基准性能的配额。

6.5 扩容


FusionOne Storage扩容方式为磁盘扩容，根据存储系统实际情况和企业运行业务的运行需求选择相应的扩容时间段。

扩容方式	适用场景	备注
添加硬盘	存储系统可用容量无法满足当前业务需求，且当前集群有可用空闲硬盘或槽位。	建议选择当前集群业务较少或无业务时间段操作，以防影响业务性能。 若存储系统中无空闲硬盘或槽位，可添加节点，然后再添加硬盘，从而完成磁盘扩容。

扩容流程

当FusionOne Storage存储系统可用容量无法满足使用需求时，可根据扩容流程进行相关操作。

图 6-4 扩容流程示意图




6.6 异步复制

FusionOne Storage存储可提供分钟级的异步远程复制功能。基于两套FusionOne Storage存储集群构建异步复制关系，周期性的同步主、从卷的数据，上一次同步周期数据同步完成后，到当前同步周期开始，主卷上产生的所有数据会在本次同步时写到从卷上；支持数据Failback，进一步保障数据高可用。

异步复制是通过将当前集群中的卷复制到当前集群的远端集群中来实现。异步复制的架构如下图所示，在二层网络正常互通的前提下，先在数据中心A创建“远端平台”即数据中心B用于做远程复制，然后创建“远程复制”来选择将数据中心A中的指定卷复制到数据中心B中。只有配置了“远程复制”的卷才会复制到数据中心B。

在异步复制中，配置了“远程复制”的卷所写入的数据先写到数据中心A，可以通过手动下发同步请求将卷从数据中心A同步到数据中心B或通过创建远程复制时指定的复制策略将卷定时同步到数据中心B，当数据中心A故障时，需要手动分裂卷来停止数据复制然后将对应卷关联的相关业务手动切换至数据中心B。

图 6-5 异步复制示意图



使用场景

- 跨数据中心保护数据副本

由于异步复制可以对卷做跨数据中心（跨集群）同步，在其中一个数据中心故障的情况下，另一个数据中心保存了最近一次同步后的完整数据，对部分企业来说，虽然可能会丢失小部分数据，但大体上另一个数据中心还是能够接管相关业务并持续提供服务。

- 降低灾备解决方案的成本

由于配置了“远程复制”的卷才会被复制到“远端平台”，因此两个数据中心均可以根据业务需求创建卷提供给各自的数据中心业务使用。相比需要单独采购硬件的传统灾备解决方案，异步复制以较低的成本实现了跨数据中心的灾备解决方案。

6.7 延展集群

业务的持续运营对企业来说至关重要，随着信息化技术的快速发展，企业业务高度依赖于信息系统，信息系统的业务中断可能影响企业生产业务的开展，造成巨大的经济损失及严重的社会影响。因此，保障业务连续性是信息系统建设的关键。


存储系统作为数据服务的基石，存储着信息系统的所有文件，业务的连续性离不开存储系统的容灾体系建设。目前，部分企业的灾备系统建设思路主要是通过建设灾备中心来提高信息系统的业务连续性，做法是在灾备中心保留生产数据副本，在正常情况下，灾备中心不对外提供业务访问，生产中心运行时产生的数据定时同步到灾备中心，当生产中心故障且无法短时间恢复时，灾备中心接管生产中心业务。这种灾备系统通常会面临以下问题：

1. 存在一定的数据丢失风险。生产中心的数据是定时同步到灾备中心的，如果在同步间隔期间生产中心故障，新增数据还未同步到灾备中心，会导致部分数据丢失，即便是实时同步的情况下生产中心发生故障时数据没有完全同步到灾备中心，也会存在少量数据丢失的可能性。
2. 故障时业务中断时间长。当生产中心发生故障且无法短时间恢复时，需要手动将业务切换到灾备中心并进行相关调试，业务中断时间长。
3. 资源利用率低。正常情况下，灾备中心不提供服务，相关资源常年属于闲置状态，资源利用率低。

面临上述问题，FusionOne Storage块存储延展集群技术应运而生，能够确保在存储系统发生故障、甚至在单数据中心故障时，存储业务自动切换，实现RPO（Recovery Point Objective）=0，并通过结合负载均衡技术，实现业务中断无感知，RTO（Recovery Time Objective）≈0。

延展集群是FusionOne Storage块存储的高级特性，通过将普通的存储集群延展为跨两个数据中心的集群来实现。延展集群的架构如下图所示，在二层网络正常互通的前提下，由数据中心A、数据中心B和仲裁节点三部分共同组成一个存储集群。

在延展集群中，写入的数据按照设定的副本数量（支持2、3、4副本）分别同时写入两个数据中心，当其中一个数据中心故障时，业务能够自动或手动切换至另一个数据中心。



6.8 精简配置

FusionOne Storage块存储提供了精简配置功能，为应用提供比实际物理存储更多的虚拟存储资源。相比直接分配物理存储资源，可以显著提高存储空间利用率。

采用DHT路由技术，系统无需使用专门的集中元数据来记录卷的精简分配情况，和传统SAN相比，不会带来性能下降。

6.9 卷克隆

FusionStorage块存储提供链接克隆机制，支持从卷快照创建链接克隆卷，支持将链接克隆的卷拍平操作，即从原始的快照信息进行分离。

6.10 节点冗余设计

FusionOne Storage存储采用分布式集群管理方式，从架构上保证了系统不会出现单点故障，一个节点或者一块硬盘故障自动从集群内隔离出来，不影响整个系统业务的使。任意节点故障（无论是人为故障或机械故障），均不会对系统可用性造成影响，配合节点过载控制，可有效降低接入节点故障对系统整体可用性的影响。

6.11 卷独占

卷独占保证分布式锁的状态机不会异常、业务只能从一个客户端下发。保护逻辑卷数据一致性，对逻辑卷做修改时，需要持有此锁。

7 NAS 存储特性

7.1 NAS存储高可用技术

7.2 NAS存储接口

7.3 配额

7.1 NAS 存储高可用技术

FusionOne Storage存储系统是一套分布式存储系统，文件存储构建于分布式引擎之上。文件存储的关键模块是文件系统、协议和文件网关。文件系统是提供文件存储接口语义的基础，实现文件形式的存储访问，同时提供文件级的特性，如配额、快照等。协议对外提供NAS协议的访问，直接和客户端进行会话。文件负载均衡及高可用技术则是依托于文件网关实现，用于保证文件存储业务的高可靠和高性能，同时支持不同部署形式，以匹配整体节点资源消耗。


FusionOne Storage存储系统中，文件网关利用浮动IP实现高可用。文件网关由集群中的多个服务器节点组成。文件网关中的每个节点都可以对外提供文件共享服务，当其中一个节点故障时，同一网关中的其它节点接管该节点上的文件共享服务。

7.2 NAS 存储接口

FusionOne Storage的NFS和CIFS依托于tcp/ip协议，不同协议通过不同的网络端口进行会话，客户端会话通过网络层到达协议层，协议层解析协议请求然后转化为文件系统语义，然后调用FS层接口最终将请求发到文件系统。请求返回过程相反。

同一文件系统可以同时提供NFS和CIFS访问，不同客户端看到的同一个文件系统是完全一致的。文件系统按照协议标准保证元数据一致和数据持久化，NFS客户端写的文件可以通过CIFS客户端立即访问到，CIFS客户端写的文件也可以通过NFS客户端立即访问。为了保证业务行为的数据一致性，建议CIFS、NFS客户端不要同时写同一文件共享下的同一文件。

图 7-1 文件业务流程



NFS共享采用IP认证权限，支持只读、读写方式访问共享，支持root_squash、all_squash开关配置，满足客户端将root或所有用户映射到匿名用户（即等于nfsnobody用户访问），便于权限控制。

CIFS共享采用用户认证，支持本地用户本地认证（默认）、AD认证和全局认证。本地用户即存储系统中创建的文件用户，注意不是系统管理员。AD认证支持与AD域对接，满足通用办公场景。支持配置是否允许来宾访问（即无需用户信息即可访问）。

技术特点

- 兼容性好：NFS支持最通用的NFSv3，CIFS支持SMB1、SMB2、SMB3，基本满足所有类型的客户端访问。文件系统基于POSIX语义，兼容所有的文件操作，满足各种业务需求。
- 跨协议访问：Linux客户端通常使用NFS，Windows客户端通常使用CIFS，不同客户端同时访问同一文件共享，可以实现数据跨协议的访问。
- 快速使用：FusionOne Storage不需要客户端额外安装软件，只要在存储侧配置好共享，Linux客户端或Windows客户端就可以直接访问使用，直接进行文件访问，如同本地文件系统一样操作。
- 共享方便：不同的客户端或不同类型协议的客户端均可以同时访问同一文件系统，数据完全共享，不存在难以互通的问题。
- 权限管控：基于客户端和用户的鉴权方式，支持对接AD域，精细化控制客户端或用户的读写访问权限，保证数据共享安全。

7.3 配额

FusionOne Storage文件配额包含用户配额和目录配额，支持容量和文件数限制。

用户配额

用户配额需要依赖用户，因此FusionOne Storage NAS存储实现了文件用户管理，包括用户和用户组。文件系统用户配额按照用户和用户组设置，单个用户可以属于多个用户组，而用户组也可以包含多个不同用户，满足群组使用的控制。

当文件系统产生文件和数据时，文件的owner和group表示数据的使用者，配额模块会将使用情况统计到存在的配额条目中，如果配额达到上限，将拒绝业务。

目录配额

目录配额依赖于文件系统目录，目前支持文件夹一级目录配置目录配额，目录需要通过系统API调用创建（通过协议客户端创建的目录暂不支持配置配额）。

当文件系统对应存在配额的目录写入文件或数据时，配额模块会统计此目录的使用情况，然后查看是否超过配额，如果超过配额则会拒绝业务。

技术特点

- 使用方便：文件存储用户配额和目录配额可以满足文件夹合理使用需求，防止单一用户或目录占用了太多存储空间。同时支持通过API调用进行统一化配置管理。
- 管理简单：配额拥有实时的资源占用统计情况，而且可以实时在线修改。当业务因为配额不足时，业务会产生配额不足错误，明确提示业务扩容配额或删除数据。

8 对象存储特性

8.1 对象存储负载均衡及高可用

8.2 小文件在线合并

8.3 对象多版本及CDP技术

8.4 对象生命周期管理

8.5 授权管理

8.6 对象压缩

8.7 对象重删

8.8 对象预览

8.9 对象检索

8.1 对象存储负载均衡及高可用

对象存储系统采用浮动IP+负载均衡器的方式实现服务的负载均衡及高可用。

浮动 IP

集群的浮动IP使用Keepalived高可用集群进行管理，keepalived使用多主模式进行部署，每个keepalived节点绑定一个浮动IP，由keepalived来保证浮动IP的可用性。

在某个keepalived节点出现故障时，keepalived集群会自动将对应的浮动IP迁移到其他keepalived节点，从而保证浮动IP的可靠性。

负载均衡

负载均衡器基于LVS（Linux virtual server）模块实现。LVS技术实际上是一种基于代理服务器的负载均衡技术，请求通过代理服务器转发给后端的内部服务器处理请求，从而提高处理能力。

图 8-1 负载均衡及高可用示意图



技术特点

对象存储系统提供的负载均衡及高可用方案，具备高性能、高可靠性等优点，能够在实际生产使用时发挥出存储集群的整体性能。快速的故障切换能够大大缩短节点故障所带来的切换时间，保障业务连续性。

- 高效负载均衡:LVS的负载均衡器运行在七层网络架构的会话层进行转发，相比其他开源的负载均衡器有更高的转发效率及转发性能。
- 兼容多种网络环境:所采用的负载均衡及高可用方案能够在VLAN及VXLAN等多种网络环境下稳定、高性能工作，具备较好的兼容性。
- 快速故障切换:在节点故障的场景下，故障切换的时间能够保证在10s内完成，大大提高业务连续性。

8.2 小文件在线合并

存储集群在不同业务场景下需要面对不同数据类型的挑战。大文件（通常大于1MB）场景下，集群容量占用率达到70%时，文件数也不会太多，存储访问性能较稳定，受文件数量影响较小。但是在海量小文件（通常小于1MB）场景下，系统中的文件数会逐渐增加，相比大文件场景会有超过百倍以上放大，系统面临着更高的海量数据存储管理的挑战。

虽然分布式对象存储系统相比传统文件系统可以承载更大的文件数量，但还是更加适用于大文件存储。如果不对大文件和小文件分开处理，存储性能可能会在海量小文件场景表现为性能随容量增加迅速下降或者空间浪费严重。例如70%已用容量相比空集群读写性能下降10倍以上，而集群空间占用也放大到实际文件总大小的2倍或者更多。


小文件合并技术应运而生，主要解决海量小文件带来的性能和空间浪费问题，常见的小文件合并有在线合并和离线合并。在线合并为文件写成功即合并成功，拥有较高的技术难度，效果最好。离线合并对文件第一次写入不做改动，而是等后期再单独对文件进行合并，存在读写压力放大，效果其次。

FusionOne Storage采用小文件在线合并技术解决海量小文件场景下的存储性能和空间占用问题。

技术原理

小文件合并即多个对象共享一个物理文件。在线小文件合并的原理是小文件写入之前，系统会分配适合大小的大物理文件用于存放文件数据实体，然后文件数据实体实际被通过追加写方式写入一个大文件中，作为大文件的一部分。这样多个文件写入后就自动合并成了一个大文件。

图 8-2 小文件在线合并



文件写入过程中会映射和寻找适合的大对象，写入成功后更新大对象的状态属性，此时小文件的索引也记录了数据实体所属的大对象和对应的数据范围。之后需要获取小文件时，通过小文件索引的记录直接获取数据。

同理，对象文件的删除、同步、转移等特性也基于小文件合并的原理进行，删除后识别回收大文件，同步和转移继续保持合并状态，保证业务高效和正确。

技术特点

使用小文件在线合并技术，一套存储就可以支持不同业务类型，不管是大文件还是小文件场景或者混合模型，存储系统都可以应对自如。一方面不用担心集群使用率上升会带来性能严重下降问题，同时可以防止空间占用过高引起的资源浪费，降低后期扩容风险，降低采购成本。

小文件在线合并使存储拥有更大更好的规格体验，单桶10亿文件可以满足大部分的业务需求，业务无需人工划分数据分桶，降低业务规划难度和管理成本、降低数据需要迁移的工作量和风险和运维难度。

- **性能稳定**

小文件合并直接解决存储在海量小文件下的性能问题，集群容量达到70%以上性能也不会下降超过20%。采用小文件在线合并，文件的写入和读取的方式发生了变化，但是读写依然是一次性完成，没有额外的耗时动作，时延相比没有变化。而且相比离线合并不会带来后续的读写放大，不会额外增加系统压力。

- **规格可靠**

采用小文件在线合并，存储集群可以支撑更大体量的文件数量，可以达到单桶至少10亿、整集群1000亿或者更大规格。系统自动合并设定范围的小文件，除了默认的合并规则，系统还支持手动调整或优化小文件的识别界限、合并大文件的个数和大小，可以根据实际环境配置和业务保证更好的业务体验。

- **节省空间**

一个大文件可以合并几十个小文件（默认80），数据实体的大小都是大文件级别，文件的实体数量得到降低，在海量文件数下可以降低空间占用。

8.3 对象多版本及 CDP 技术

在对象存储领域，最常用的数据保护方式为多版本技术。对象存储通过对数据的版本控制，能够有效防止用户数据的误删、误覆盖、误修改等逻辑错误，在存储系统本身提供了数据的备份-恢复能力。

除此之外，对象存储在多版本技术的基础上进行了增强，实现了持续数据保护特性（CDP），能够回滚到某个时间点的数据状态。

技术原理

- **多版本控制**

多版本技术中，实际上即是对对象版本的控制。开启多版本的情况下，每个对象都会携带版本号，在上传相同文件名的对象时，不会直接覆盖原有的对象，而是通过使用新的版本号的方式标记新的对象，新旧版本同时存在。与此同时，存储系统会将对象当前的版本指针指向最新的版本，在用户正常使用的情况下，只能看到当前最新版本的对象。

- **版本回滚**

开启多版本后，可以通过特定的接口，查看对象的当前版本和所有历史版本，多个版本之间能够进行回滚。

版本回滚的操作，实际上就是将当前版本指针，指向某个历史版本，从而在用户访问时能够访问到老版本的历史版本。


- **删除标记**

使用多版本技术后，删除文件不会将实际的文件进行删除，而是通过创建一个特殊的空对象的方式来进行处理。这个空对象称为删除标记，历史的所有版本也会继续存在。

当某个对象的最新版本是删除标记时，用户使用普通的接口无法找到这个对象，从表现上来看这个对象已经被“删除”了。

带上删除标记的对象也能够通过版本回滚的机制，将历史版本恢复。

图 8-3 多版本示意图




- **版本日志**

基于多版本特性，对象存储系统额外开发了持续数据保护功能，用户能够直接将数据回滚到某个时间点的状态。

每个版本变更时，会将版本变更的信息记录到版本日志，从而记录版本的变更信息。当用户回滚到某个时间点时，会将该时间点到最新时间的版本日志做一次扫描，将所有的更改进行回滚，新增的文件会打上删除标记，原有的文件会被回滚到指定时间点的版本。

为了防止版本日志过于庞大，因此一般只保留最近7天的版本日志，超出7天的日志将会被覆盖。

图 8-4 CDP 示意图



技术特点

- 数据保护：多版本机制能够有效地保护用户的重要数据，在误删、误覆盖、被篡改的场景下，提供完备的数据恢复机制，大大提高了重要数据的安全性。
- 防业务逻辑错误：对象存储特有的持续数据保护特性，能够在业务出现逻辑错误，从而导致大量数据错误的场景下，快速、自动地对数据进行回滚恢复，极大的降低了逻辑错误场景下的数据恢复成本。
- 版本控制：多版本特性能够很好地保证数据的安全性，在防误删、防覆盖、防篡改方面应用广泛。对象存储中，每个对象最多能有256个版本，超出的版本将会覆盖最老的版本。
- 高性能：对象存储对多版本场景下进行了许多性能优化，保证开启多版本后的性能与未开启前持平。

8.4 对象生命周期管理

生命周期管理是企业管理中重要的一项工作，是对产品、数据等内容从产生到回收的一系列管理过程，它既是一门技术，又是一种制造理念。

对象存储中的生命周期管理技术，即客户根据不同业务数据的生命周期特点，自定义生命周期管理策略，由存储系统自动按照策略执行生命周期管理的一项技术。

良好的数据生命周期管理策略，能够更好的利用存储系统，降低存储成本，降低管理复杂度。

技术原理

对象存储的生命周期管理，主要从时间的维度对数据的生命周期进行度量，超出时间范围的对象，会触发相应的生命周期处理策略。

对象存储中，超出生命周期的处理策略是过期删除策略：针对超出生命周期时间的数据，采取删除操作，回收存储空间。

技术特点

FusionOne Storage存储中的生命周期管理，能够大大简便企业数据的生命周期管理，并且支持多种管理粒度，更好的适应企业需要。

- 自动执行生命周期策略：生命周期策略设置完成后持续生效，管理无需人为干预，自动处理过期数据。
- 多粒度生命周期管理：支持针对整个桶设置生命周期，也支持对桶中部分子目录或携带特定前缀的对象设置生命周期。
- 生命周期的影响控制：生命周期的执行主要是数据的删除，会损耗一定的存储性能。FusionOne Storage能够限定生命周期执行的时间段，在业务空闲时间执行，控制生命周期执行过程中对业务的影响。
- 基于对象标签的精确控制：对象存储系统在标准的生命周期功能上，额外研发了基于对象标签的生命周期管理策略，针对拥有特定标签的对象制定单独的策略进行精确控制。

8.5 授权管理

对象存储相比传统的文件存储，在移动互联网时代有更好的适应性，在任何能够使用HTTP协议的终端，都能够访问对象存储，从而使得对象存储有着更广泛也更复杂的应用场景。

更多的应用场景，同时也意味着需要更完善的授权管理机制来保证访问安全及数据共享。

对象存储通过多用户机制来管理、隔离用户的数据，通过鉴权技术来保证访问安全，使用桶共享策略技术、外链技术来实现数据的共享。

技术原理

- 多用户
多用户技术在对象存储中是最常用、最基础的权限管理技术。
多用户技术支持存储管理员创建多个对象存储用户，每个用户的数据相互隔离，互不影响。每个用户上传对象时，都会携带owner信息，说明数据的属主，从而实现数据的隔离。
- 鉴权
访问对象存储时，需要使用用户的鉴权信息来进行鉴权，鉴权通过后才能访问对象存储中的数据。
完成鉴权所需最基础的信息为access key及secret key，客户端访问时需要使用access key及secret key使用加密算法生成签名，在向对象存储发送请求时，将access key及签名一同发送给存储系统，存储系统会根据access key找到对应用户的secret key，随后使用客户端相同的加密算法生成签名，通过对比计算出的签名与客户端发送过来的签名是否一致，从而判定鉴权是否通过。
除了使用access key及secret key生成鉴权信息，也可以额外将HTTP Header中的字段加入到鉴权过程中，提高签名复杂度，进一步提高请求安全性。
- 桶共享策略
由于多用户技术的存在，正常情况下，不同的用户无法访问到对方的数据。在实际的应用场景中，数据的共享非常常见，桶共享技术能够满足用户的数据共享需求。
桶共享策略能够将桶或桶内的某个子目录下的对象以不同的操作权限共享给其他用户或全部用户。

用户发出请求访问桶时，存储系统会先根据在这桶上的共享策略，判断用户是否具备访问权限，进而允许或拒绝用户的访问请求。

- 外链

外链技术是一种预签名技术，通过外链技术共享出来的对象，对方不需要拥有 access key及secret key就能够进行访问。

外链技术共享对象时，存储系统需要将访问对象的URL进行预签名，预签名需要的信息有：请求的部分信息、过期时间戳，随后存储系统会根据这些信息生成一个外链（临时的URL）供用户访问，这个URL在超出时间后会失效。

在用户访问外链时，请求的信息需要与生成预签名信息时的信息相匹配，否则也会访问失败。

技术特点

对象存储系统中的授权管理机制，从多个维度去保证数据的访问安全及共享安全，适应企业用户管理、数据隔离、共享管理的多方面需求。

桶共享的操作权限有以下几种：

- 只写：限制用户访问已共享的桶。
- 只读：以只读方式将桶共享给其他用户，用户只能读取，无法写入。
- 读写：以读写方式将桶共享给其他用户，用户能够随意读写数据，但无法更改桶的权限信息。
- 全部：授予其他用户完全的控制权限，包括读写、桶权限修改等。

另外，还能够添加共享的授权条件，进一步控制用户的共享访问。

- IP等于：指定用户只有使用特定的IP访问时，才能够访问共享的桶。
- IP不等于：指定用户无法使用某个IP来访问共享的桶。
- 时间点不超过：指定用户只能在某个时间点之前才能访问共享的桶。
- 基于标签的控制：只共享桶中带有指定标签的对象。

生成外链时使用的请求信息与访问外链时携带的请求信息需要保持一致，这些信息主要包括：

- Content-type信息：请求中携带的content-type字段。
- Header信息：请求中携带的Header字段。

8.6 对象压缩

对象压缩与对象重删技术都是针对目前企业数据信息量的快速增长，两种技术都是为了缩减系统所需要的存储容量，尽量提高空间利用率，降低数据存储成本，从而提升企业的投资回报率，但是两种技术具有不同层面的针对性，简单地说，重删就是将相同的对象只存储一次，而压缩则是通过一种算法来统计数据的规律从而改造数据排布，以减少数据存储空间占用。

对象数据压缩和对象数据重删对存储空间的节省效率与数据的类型强相关。在实际应用中，可以根据如下的原则选择对象数据压缩特性：

在某些归档备份场景，数据的价值密度比较低，客户希望尽量能够节约成本，可以考虑开启数据压缩技术，通过对对象文件进行压缩，降低存储空间成本，可以有效满足客户降低总体成本的需求，但是对于已经通过硬件设备或应用程序（包含备份和归档应用程序）进行压缩或者加密的数据，不推荐进行数据压缩。


技术原理

对象压缩技术是一种减少数据的冗余和存储空间的技术，压缩技术实现的前提是信息的数据表达存在冗余，是指在不丢失有用信息的前提下，按照一定的算法通过对数据重新组织，即通过检索冗余数据并采用更短的指针表示来实现缩减数据容量。

数据压缩技术通过对单个文件或单个数据块消除数据的冗余，主要通过字符串匹配算法来检索相同数据块，简单来说，就是将一个大字符串中的子串用一个很简短的数字来标记，然后检索该字符串出现的位置，用个简单的字符来替代，从而来减少数据表达所需要的空间。另外数据压缩技术的冗余粒度会很小，可以到几个字节这样的小数据块，而且是自适应的，一般不需要事先指定一个粒度范围，越小的数据块粒度会获得越大的数据消冗效果，但计算消耗也更大。


对象压缩特性在存储架构上涉及上传数据、下载数据和复制对象等模块流程，在上传文件流程中，检查桶是否开启了压缩功能，若开启了压缩功能则先对数据进行压缩处理后，再下发至存储系统层，并将相关压缩信息记录在索引中。在对象下载、复制的流程中，检查对象的元数据记录是否有压缩信息，如果有则使用元数据记录的压缩方法进行解压，然后再将解压后数据发给客户端。

图 8-5 对象读写示意图



对象压缩的示意图如图8-6所示，不同的文件或者数据片段压缩比率是不一样的，一个4M数据块压缩后可能是3M、2M，或者也有可能是几十至几百KB。对象压缩特性可以查询桶内压缩文件数量、原始数据容量大小及实际占用空间大小，从而也可以计算出数据的实际压缩比率。

图 8-6 对象压缩示意图



对象压缩特性可以按照桶粒度设置数据的压缩开关，压缩及解压过程在文件上传和下载等具体流程中，由对象存储服务网关层自行处理，对用户无感知。

技术特点

- 用户开启对象压缩以后可以直观的查看存储文件数量、压缩文件数量、原始数据总存储量及实际占用存储空间大小，简单高效地计算出数据的整体压缩比率，可在管理界面直接展示节省空间。
- 开启对象压缩特性后，在多站点之间进行数据同步时直接传输压缩后的数据，从而节省传输带宽，提高数据同步效率，同时在执行生命周期转移功能时同样也是直接转移压缩数据，实现数据的快速转移，提高转移效率。
- 对象压缩技术可以通过手动设置数据压缩文件格式的黑白名单，根据对象的格式决定是否进行压缩。

8.7 对象重删


随着对象存储的应用领域越来越广泛，企业数据中心存储需求量越来越庞大，数据量呈指数级增长，已从之前的TB级上升到PB级甚至EB级。随着企业数据信息量的不断增加，企业需要不断购置大量的存储设备去解决“数据无休止增长”带来的数据存储问题，使得空间要求、散热、能耗等问题日益突出，多套异构存储集群资源也大大增加了存储管理的复杂性，造成数据中心的运营成本、数据管理成本不断上升。同时，容易造成存储资源浪费、空间利用效率低等问题。

随着应用系统所保存的数据时间周期越来越长，企业各部门对数据的调取和存储，会出现相同文件的多次存储情况，因此文件冗余比例也上升。FusionOne Storage对象存储重删功能解决了重复数据空间占用问题，缩减系统所需要的存储容量，提高存储空间利用率，降低了数据存储成本，大幅提升了投资回报率。

技术原理

对象重删是指对象存储中的重复数据进行删除，旨在减少存储系统中数据占用的存储容量，以达到节省存储空间的目的。重删功能通过将对象文件指纹数据跟系统指纹库对比分析，可判断对象是否相同。如果是相同对象则删除多余的对象副本，仅保留一份对象数据，重复对象更新自己的元数据，指向同一对象数据实体；如果不存在相同对象，则不需要重删操作，将对象指纹更新至指纹库，即保证了重复的数据仅在磁盘介质上写一份，其它重复的副本建立“索引”，这样可以有效地节省存储空间。

图 8-7 对象重删示意图



- 对象重删的主要流程如下：
1. 上传对象文件。
 2. 对象写入成功后添加到重删队列。
 3. 获取对象的MD5值，查找指纹库，判断对象是否需要进行重删，如果已存在，说明需要重删。
 4. 对于需要去重的对象，删除重复数据，更新元数据指向同一对象实体数据，则对象文件写完成。
 5. 当业务需要删除对象时，如果对象数据存在其他对象引用，则只删除当前对象的相关引用；如果对象数据只剩当前对象引用，则进行更新指纹库，同时删除数据，保证一致性。
 6. 如果不需要重删操作，将对象MD5值更新至指纹库。

技术特点

FusionOne Storage数据对象重删功能可以实现从存储系统的多个管理维度实现不同粒度、不同方式的对象重删，满足客户多层次数据管理需求。对象重删技术可以消除冗余数据，因此采用对象重删技术可以在给定数量的磁盘设备上存储更多的数据，极大节省存储空间，提升空间利用率，减少数据中心设备数量及电力消耗，降低运营成本。

同时可以防止空间占用过高引起的资源浪费，降低采购成本。

- **重删范围粒度策略**
对象重删功能基于存储池范围可以按照全局、用户、桶粒度设置重删开关，即可以按照站点、用户以及桶粒度开启或关闭重删特性。桶的配置优先级高于用户，用户的配置优先级高于全局配置。默认情况下重删特性是未启用的，通过设置对象重删特性开启后，系统就会按照开启的重删范围扫描新写入的对象并进行重复数据删除。
- **重删对象粒度**
支持对象级、分片级重删，分段上传的对象可以选择按照分片来重删还是按照整体来重删，按整体重删需要重新计算整个对象的MD5值，去重率比较高，但会增加部分性能消耗，按分片重删则直接使用现在保存分片的MD5值，采用这种方式可以避免性能的额外消耗。
- **重删方式**
FusionOne Storage对象存储采用异步重删方式，对象写入成功后才会进行重删处理，因此不会影响业务写性能。

8.8 对象预览

图片预览功能

FusionOne Storage分布式对象存储系统在预览jpg和bmp格式的图片时，支持默认最佳比例全屏预览，且允许用户通过键盘上下键切换上一张、下一张图片。

图片在线编辑支持输入文字

FusionOne Storage分布式对象存储系统在线编辑图片时，支持输入文字，并可以定义字体（微软雅黑及免费字体）、颜色、字体大小。

8.9 对象检索

支持批量检索

FusionOne Storage分布式对象存储系统不仅能够支持百亿级对象数量的存储，还支持检索功能，即使数据量达到百亿级，仍能够提供快速批量检索

- 支持定义一批value进行搜索，value最多支持1w条。
- 通过导入csv格式的方式检索相关数据。

DataExplorer 支持按照时间标签的时间范围检索数据

FusionOne Storage分布式对象存储系统在检索模板中，能够定义需要检索的标签为时间类型，并在数据管理系统中允许根据某个指定标签的时间范围检索到相应的数据。

9 文件存储特性

[9.1 技术背景](#)

[9.2 技术原理](#)

[9.3 技术特点](#)

[9.4 客户价值](#)


9.1 技术背景

DFS是基于对象接口的高性能数据湖文件网关，支持HDFS接口和POSIX语义的文件系统接口。DFS可应用于人工智能/机器学习训练场景，以及大数据存算分离场景，通过提供POSIX语义兼容的文件接口、HDFS接口及API接口实现跟多种客户端应用平台对接，以提供海量、弹性、高性价比的大数据存储解决方案。DFS的客户端可以是普通Windows或Linux等服务器，也可以是Hadoop或Kubernetes集群。

9.2 技术原理

DFS的核心组件分为元数据服务模块和客户端模块两个部分。

图 9-1 DFS 架构图



元数据服务模块

即DFS元数据管理集群MDS，元数据服务用于管理文件系统中所有文件的元数据信息，如文件名、目录结构、文件大小、修改时间等。元数据服务是一个分布式集群，基于Raft一致性协议，保证元数据强一致性的同时，还能确保集群的可用性。同时元数据服务也支持横向扩展功能，能够很好支持百亿级文件规模。

MDS所运行的节点可以是独立的服务器，也可以是OSD或者Monitor所在的服务器，需配置独立的SSD以存储DFS的元数据。当DFS性能要求较高时，建议采用配置了SSD的独立服务器作为MDS的节点。

客户端模块

客户端是用户与DFS交互的入口，目前支持多种类型的接口，包括POSIX、Hadoop API等。通过FUSE（Filesystem in Userspace）可以很方便地将DFS挂载到任意系统的机器上，因为DFS完全兼容POSIX接口，应用程序无需做任何适配即可直接使用DFS。DFS同时还提供Hadoop Java SDK，完全兼容Hadoop文件系统接口。同时，为了解决存算分离后存储与计算之间的网络延迟问题，DFS提供了客户端缓存能力，可利用客户端的内存或SSD资源，提升数据的读写性能。此外针对业界使用比较广泛的CDH平台，DFS也开发了配套的Parcel资源包，利用CDH自身的管理即可便捷的配置使用DFS提供的存储空间。

9.3 技术特点

协议支持

DFS是POSIX兼容的文件系统，可以支持各种依赖POSIX协议的应用。DFS也是HDFS兼容的文件系统，通过DFS Hadoop SDK接入Hadoop生态可以完美支持所有计算引擎。此外，**DFS CSI驱动**实现了**容器存储接口（CSI）**规范，用于在容器编排器中管理DFS文件系统生命周期。

快照

快照是在某个时间点（拷贝开始的时间点）对指定数据的完整映像，这是数据备份时经常用到的技术。DFS的快照在建立快照时不会实际拷贝文件数据，而且创建一套完整的引用，在源数据发生修改时才拷贝数据（Copy-on-Write技术）到快照中。

压缩

DFS客户端在将数据写入对象存储时可以对数据进行压缩，默认采用LZ4压缩算法，也可以使用Zstandard压缩算法。对应的，当从DFS读取时也会自动解压数据，做到应用透明。数据压缩功能可以关闭。

权限控制

DFS的权限分为两种，适用于不同场景下对客户端的权限控制：

- 基于令牌（Token）认证。
在用户挂载前，客户端需要输入要挂载的文件系统的Token，服务端对比Token是否跟配置文件一致从而返回认证成功或者失败的信息，若Token不正确则无法挂载，进而控制客户端的挂载。
- 通过创建权限来控制用户对文件系统的访问权限。
文件系统创建后，通过设置可访问文件系统的IP网段、读写权限、当前文件系统的Qos来控制用户访问文件系统的权限。此外，在客户端挂载时，带上相关的参数可控制当前客户端访问文件系统的Qos。一个文件系统可以创建多条权限规则，对多个客户端做不同的访问控制。

配额

DFS的配额可对文件系统及其子目录设置inodes个数及目录容量的限制。一个文件系统可以创建多条配额规则，对不同的子目录做配额控制。

客户端缓存

为了提高性能，DFS实现了多种缓存机制来降低访问的时延和提高吞吐量，包括数据缓存、多个客户端之间的缓存共享。

- 数据读缓存。
适用于一次写入多次读取的场景，客户端会根据应用读数据的模式自动做预读和缓存操作以提高顺序读的性能。数据会缓存到本地文件系统中，可以是基于硬盘、SSD或者内存的任意本地文件系统。

缓存在使用空间到达上限时（或者磁盘空间快满时）会自动进行清理，目前的规则是根据写入时间和大小，优先清理更大和更老的文件。

数据的本地缓存可以有效地提高随机读的性能，建议使用更快的存储介质和更大的缓存空间来提升对随机读性能要求高的应用的性能。

- 客户端写缓存。

客户端会把应用写的数据缓存在内存中，一定时间之后再写入到对象存储中，客户端会等数据写入到对象存储并且通知元数据服务后才返回，以确保数据安全。在某些情况下，如果本地存储是可靠的，可以通过启用异步上传到对象的方式来提高性能，此时不会等待数据写入到对象存储，而是写入到本地缓存目录就返回。

- 客户端缓存组共享。

当同一个集群的客户端需要反复访问同一个数据集时（比如机器学习时需要用同一个数据集反复训练），DFS提供了缓存共享功能，可以有效地提升这个场景下的性能。缓存共享即客户端的分布式缓存，是将一个cache group的所有客户端的磁盘缓存空间当做一个整体，数据块通过一致性哈希算法分布在这些客户端的缓存目录。缓存共享功能非常适合使用GPU集群进行深度学习训练的场景，通过把训练数据集缓存到集群所有节点的内存中，可以提供非常高性能的访问，让GPU不会因为数据读取太慢而闲置。

9.4 客户价值

DFS为用户提供了多协议接入的能力以及高性能的数据访问能力，是企业数据湖的最佳存储底座。

- 大数据平台场景：传统Hadoop集群使用HDFS作为存储系统，在云原生环境下无法弹性扩缩容，而且使用云盘搭建的HDFS成本提升3倍。如果换用对象存储也存在新的问题，包括性能明显下降、缺少一致性保证、权限管理不兼容等。DFS具有完整的HDFS兼容性，实现存储计算分离的架构升级，为大数据平台增效降本。
- AI平台场景：AI的能力已经应用在各行各业中，百亿级文件管理就是业界难题之一，其它还有性能、可用性、数据共享、对训练框架的兼容性等，DFS已经一一解决上述问题。
- 容器平台共享存储场景：当应用向Kubernetes容器平台迁移时，有状态应用的数据如何存储和管理是一个关键问题。Kubernetes提供了CSI存储接口和Persistent Volume机制，DFS是这类场景中的理想选择。

10 可靠性

10.1 软件可靠性

10.2 硬件可靠性

10.1 软件可靠性

10.1.1 快速 IO 重试

FusionOne Storage支持的快速IO重试特性，确保单点亚健康的IO时延可控，主要通过如下两种机制实现。

- 时延检测：每IO检测是否超阈时间未返回，如未返回则启动IO重试。
- IO重试：对于读IO则读其他副本或降级读，对于写IO则在其他盘中分配空间。

10.1.2 亚健康管理

亚健康，也称Failslow，是指对应硬件可以正常运行但性能低于预期的一种状态。导致亚健康的原因非常多，包含但不限于Firmware Bug、硬件自身设计缺陷、温度、环境（如震动）、配置错误等。

多种硬件均有可能进入到亚健康状态，包含但不限于硬盘和网络，一旦某硬件进入到亚健康状态，如果存储系统未采取有效监控和容错，则极有可能会造成存储系统响应主机的时延增大、IOPS/BPS降低，甚至导致无法响应主机，进而导致主机业务中断。FusionOne Storage存储系统支持对硬盘和网络进行全面的亚健康状态监控，并进行智能诊断后实现自动隔离，实现单部件亚健康存储系统性能无感知，让主机享受一致性性能体验。

10.1.2.1 节点亚健康管理

分布式集群节点在运行过程中出现软硬件问题是普遍现象。由于节点软硬件问题导致节点进入亚健康状态，比如网络故障，内存反复纠错导致访问降速等；在这种场景下，整系统服务时延受到单个节点影响而降级。针对这一类问题场景，FusionOne Storage系统通过收集时延信息检测出处于亚健康状态的节点，对问题节点或节点的问题资源进行隔离。

10.1.2.2 硬盘亚健康管理

FusionOne Storage存储系统对其使用的数据盘均实现了全方位的亚健康状态监控，主要监控内容包含但不限于：

- SMART信息：在SMART信息中的TYPE字段为“pre_fail”的项WHEN_FAILED是否为failing_now或in_the_past，则判断为亚健康硬盘
- 亚健康判定检测指标全面，包括SMART信息、IO时延等异常。
- 智能隔离：基于捕获到的异常信息，能够结合存储系统状态，在保障数据不丢失的情况下，自动隔离异常组件，快速恢复集群状态，避免集群性能大幅波动。

10.1.2.3 网络亚健康管理

网卡降速，丢包/错包率增加等都会导致集群网络性能降级，进入亚健康状态。系统通过检测网络资源状态的变化，定位受到网络亚健康影响的节点，进行bond主备切换或者节点隔离。基本原理是：

- 多级检测机制：节点本地网络快速检测丢包、降速等异常。并智能选择节点自适应发送探测包，识别链路时延异常和丢包等问题。丢包默认阈值为：5%，时延默认阈值为：100ms。
- 智能诊断：结合组网模型和异常信息进行智能诊断，识别网口/网卡/链路等异常。
- 亚健康判定检测指标全面，包括丢包率、降速及链路异常。
- 智能隔离：基于捕获到的异常信息，能够结合存储系统状态，在保障数据不丢失的情况下，自动隔离异常组件，快速恢复集群状态，避免集群性能大幅波动。

10.1.3 硬盘错误在线读修复技术

在大规模分布式存储系统中，由于硬盘数量大，虽然单盘故障概率不高，但是对于包含了成千上万块硬盘的存储系统来讲，每天发生硬盘故障的就是很平常的事情了，虽然大部分分布式存储系统具备多副本或者纠删码保护机制，但是频繁的硬盘故障会导致系统降级及反复的数据搬迁转移，对于系统可靠性及业务性能均会造成一定的冲击。


面对此问题，FusionOne Storage存储系统，基于硬盘错误类型，能够基于冗余数据自动恢复硬盘错误，提高分布式存储系统稳定性。

普通分布式存储系统针对硬盘错误处理机制有如下特征：

- “事后处理”：不能对硬盘的潜在风险进行预测，无法针对潜在的失效主动预防并隔离；
- “简单粗暴”：无法对IO路径上的错误做出及时处理和主动修复，采用直接“踢盘”的处理方式，引起集群数据不必要的搬迁；

FusionOne Storage存储系统基于如下步骤自动修复硬盘读错误：

图 10-1 硬盘读修复 IO 示意图



如图10-1所示，分为6个步骤：

- 步骤1 客户端发起读请求。
- 步骤2 遇到硬盘坏道等SCSI错误。
- 步骤3 请求副本数据。
- 步骤4 副本数据所在硬盘成功返回。
- 步骤5 主本成功从副本得到数据。
- 步骤6 返回数据给客户端，修复硬盘错误。

----结束

硬盘错误在线读修复技术通过数据副本自动修复硬盘，不仅可以避免分布式存储系统降级，提高系统可靠性，还省去了数据恢复的过程，对业务性能稳定性更加友好，同时整个系统对硬盘的容忍度更高，能够有效延长硬盘服务寿命，降低系统构建成本：

- **主动预防**：结合了硬盘静态参数和动态运行信息的主动预防机制，综合判定硬盘是否处于亚健康健康状态，针对处于亚健康状态的硬盘采取主动隔离机制，避免单盘亚健康影响集群运行稳定性，提升存储服务可用性；
- **实时感知**：实时感知硬盘IO路径上的错误，并利用副本技术在IO返回用户前修复，提高用户数据可靠性；
- **主动修复**：根据硬盘动态参数（SCSI错误码）判定并修复硬盘错误，遇到错误不随便“踢盘”，提高硬盘利用率；

10.1.4 恢复 QoS 控制

FusionOne Storage使用QoS技术（Quality of Service）限制数据恢复的速率，防止恢复流程占用过多系统资源造成业务受影响。

系统通过内部流量状态感知前端业务是否繁忙，如果业务繁忙，则会将存储资源优先分配给业务。如果前端业务空闲，则会将存储资源优先分配给数据重构。

10.1.5 数据可靠性

10.1.5.1 对象 WORM


一写多读（WORM）特性，即对数据进行保护，被保护的数据只能进行读取，不能进行修改、删除操作。WORM特性广泛应用于归档场景中，例如账单、发票、合同等数据的归档，这类文件有相关的监管合规要求，不能进行修改、删除操作。

技术原理

对象存储的WORM特性在桶的粒度上实现，每个桶都能够开启WORM特性对数据进行保护。

在客户端发起写入或删除请求时，存储网关将会判断目标对象的桶是否开启WORM特性，针对已开启WORM特性的桶，将会拒绝删除请求及旧对象的写请求，从而达到数据保护的目的。

图 10-2 WORM 请求示意图



技术特点

WORM特性能够防止重要数据的删除、覆盖、篡改，对重要数据进行有力保护。并且能够满足用户在遵从法规方面的要求，满足用户的业务要求。

10.1.5.2 数据保护

FusionOne Storage通过多副本、纠删码以及多级硬盘池来实现数据的可用性，多级硬件硬盘池，能将用户的数据及其副本分布在不同硬件硬盘池中，单一硬盘池内的硬件故障不会导致系统业务中断。


10.1.5.3 多硬盘池

在传统存储及部分分布式存储中，往往许多应用会同时使用同一套存储系统，在存储系统出现故障或数据恢复时，往往使用这套存储的所有应用系统都会受到影响。若需要实现应用系统之间的故障隔离，则需要额外一套存储系统提供给部分应用系统使用，使得某一套存储出现故障时，另一套存储上的应用不会受到影响，但两套存储系统的存在又增加了运维复杂度。

FusionOne Storage存储系统，能够在同一套存储系统中，划分多个硬盘池，通过存储策略的控制，将应用业务分布到不同的硬盘池中，实现故障隔离，控制故障的影响范围。

集群拓扑是多硬盘池技术的关键内容。集群拓扑在逻辑上维护了一份集群节点的分布拓扑图，其中包含了数据中心、机房、机架、存储节点等从大到小的逻辑实体，通过树状图的方式逐层放置，从而描述出从机房到存储节点的分布关系。其中，每一个树状图都有一个“根”，同时集群拓扑允许多个“根”的存在。

图 10-3 集群拓扑示意图



在维护了集群拓扑之后，通过制定数据的分布规则来实现多硬盘池技术。其中，数据分布规则有以下原则。

- 同一份数据只能存放在一个树状拓扑下，即数据只能在某个“根”内分布，数据的恢复、均衡等操作，也都限制在这个树状拓扑之内。
是多硬盘池技术的实现原则。
- 数据的分布存在安全级别，一份数据的多个副本不能放置在这个安全级别的同一逻辑实体上。例如，选择限定了某个存储池的安全级别为“机架”级别，则往这个存储池存放数据时，同一份数据的不同副本不能放置在同一个机架内的存储节点上，必须跨机架分布。

多硬盘池技术：通过创建多个逻辑拓扑树状图，即创建多个“根”，任何的节点故障、数据恢复都在某个树状拓扑的范围内产生影响，而不会影响到其他树状拓扑，从而实现故障隔离。

无感知扩容

在分布式架构中，节点的扩容往往意味着集群拓扑图的变化，也伴随着数据的重分布，重分布过程中，也会对集群性能产生影响。

利用多硬盘池技术，能够将新扩容的节点独立成一个硬盘池，从而避免了数据的搬迁，大大降低了对业务的影响。

10.1.5.4 多副本

当今大部分存储系统中，首要的稳定存储介质就是硬盘，数据先写入存储系统的硬盘中，后续有需要再备份到其他类型的稳定存储介质（如磁带）。一套存储系统中硬盘的增多除了带来容量和性能的提升外，也增大了硬盘故障的发生概率。人们首先想到的就是能不能将数据复制成多份，放在不同的硬盘上，这就是副本冗余技术，是最简单直观的数据可靠性技术。

FusionOne Storage块存储采用数据多副本备份机制来保证数据的可靠性，即同一份数据可以复制保存为2~3个副本。针对系统中的每1个卷，分片后的数据按照DHT算法保存集群节点上。在副本冗余策略下，各副本数据最终写入不同的硬盘。而且DHT算法可以保证各个硬盘的容量使用均衡。副本策略可以按节点或机架级感知，应用层不感知副本存在什么硬盘上。默认存储节点级时，两个硬盘属于两个不同的存储节点。此时即使一个节点硬盘损坏，数据也不会丢失。

FusionOne Storage副本冗余技术具有以下特点：

- 可靠性高：数据副本跨硬盘或机架，只要不是全部副本损坏，数据都不会丢失。
- 可配置性好：副本策略可以按节点或机架级感知配置，副本可以选择2~3，便于空间上的管理。
- 节点间容量均衡：使用DHT算法可以保证各硬盘使用率分布均衡，避免单个硬盘写满而影响整个业务。
- 故障恢复：自动恢复数据效率高，保证数据可靠性恢复到设置的副本状态。

10.1.5.5 Erasure Code


FusionOne Storage块存储支持Erasure Code（EC，纠删码）方式来保证数据的可靠性。相对三副本，EC数据冗余保护机制在提供高可靠性的同时也能够提供更高的磁盘利用率。FusionOne Storage的EC技术，可使磁盘空间利用率最高达80%，相同可用容量需求条件下，采用EC方式可以节省30%~59%左右的硬件，也更省空间、更节能。

FusionOne Storage将纠删码技术应用到数据冗余处理中。

写入的数据分为数据被拆分为K个数据块，然后编码生成M个校验块，总共K+M份数据通过DHT算法分别存入不同硬盘中。当系统出现故障，丢失了某些块时，只要丢失的块数目不超过M，就可通过数据恢复算法，将丢失的数据块从剩余的块中计算出来。在这种方式下，空间的利用率约为 $K/(K+M)$ ，数据的可靠性由M值的大小决定，M越大可靠性越高。


例如3+2 EC配置下一个对象写入时，对象会生成5个块，每个块均存入不同的硬盘，如下图所示。

图 10-4 纠删码技术示意图




默认的纠删码是按照节点来分配数据的，例如EC（4+2）需要配置6个节点，但亚节点纠删可按照硬盘来分配数据，例如EC（4+2）：1，则是把3个节点当6个节点用，每个节点选择2块硬盘，整个集群选择6块不同的硬盘来存放4+2总计6个分片数据。

图 10-5 “4+2：1” EC 策略示意图




使用EC策略后，如果读取数据时disk2和disk4异常无法返回数据，则可以通过其他硬盘数据计算出完整的对象数据。



如果写K+M的块时，有超过M个写入失败，FusionOne Storage纠删码会将对象还原到上一个完整版本中，以保证数据的一致性。

同副本机制类似，当某个节点恢复时超过一定时间（可配置），该故障节点依然无法恢复时，系统将会自动启动数据自愈，即利用现有的数据和EC校验块恢复出原有数据，保证数据的可靠性。

图 10-6 EC 计算恢复示意图



10.1.5.6 数据一致性

FusionOne Storage采用多种技术手段，包括一致性复制协议、读修复技术和数据完整性保护技术设计，保证了数据的一致性和完整性。

10.1.5.7 掉电保护

系统运行过程中可能会出现服务器掉电可能，FusionOne Storage使用SSD作为保电介质保存元数据和缓存数据，以防掉电而丢失元数据和用户数据。

FusionOne Storage存储支持SSD作为保电介质。程序运行过程中会把元数据和缓存数据写入保电介质中，节点异常掉电并重启后，系统自动恢复保电介质中的元数据和缓存数据，并把数据自动恢复到一致性状态，保证业务能正常访问。

10.1.5.8 快速数据重建

FusionOne Storage节点具备强大的数据保护和恢复机制。系统因节点、磁盘或存储节点发生故障导致数据不一致，可通过内部自检机制，自动发现数据故障并启动数据恢复机制，多个节点并行工作，有效避免单个节点的性能瓶颈，对上层业务的影响做到最小化。

FusionOne Storage每个硬盘都保存了多个数据块，这些数据块的副本按照策略分散在系统中的其他节点。当FusionOne Storage检测到硬盘或者节点硬件发生故障时，自动在后台启动数据修复。由于数据块的副本被分散到多个不同的存储节点上，数据修复时，将会在不同的节点上同时启动数据重建，每个节点上只需重建一小部分数据，多个节点并行工作，有效避免单个节点重建大量数据所产生的性能瓶颈，对上层业务的影响做到最小化。

FusionOne Storage支持并行、快速故障处理和重建：

- 数据块及其副本分散在整个资源池内，当磁盘或存储节点故障时，系统能自动进行数据重建，全NVME SSD数据盘配置，数据重建速度需能满足每TB≤10分钟，全HDD数据盘配置，数据重建速度需能满足每TB≤20分钟。
- 数据分布上支持跨节点，不会因某个节点故障导致的数据不可访问和不可重建。


故障或者扩容时可以自动进行负载均衡，应用无需调整即可获得更大的容量和性能。

10.1.5.9 数据恢复

副本冗余技术与纠删码冗余技术可以保证在一定的硬件故障场景下，存储系统不间断地对外提供业务。但是仍有可能发生某些不可逆的故障，如多台存储节点操作系统崩溃、网络全部瘫痪故障、系统内部故障等发生时，存储系统受到致命影响无法对外提供服务的场景。这种情况下，存储数据的硬盘并未全部损坏，数据仍可通过一定的技术实现抢救恢复。

FusionOne Storage提供的集群数据恢复工具，可充分应对这种极限情况。在存储系统不能对外提供服务时，将数据从发生故障的系统中完整导出，抢救客户的全部数据。恢复工具的核心原理为根据系统数据与元数据的在集群中的分布特征，定位出数据的位置，读取数据信息，当有数据损坏时，尝试根据副本或纠删码冗余信息恢复出有效数据。具体工作流程如下图所示。

图 10-7 集群数据恢复技术



- 首先获取集群拓扑信息，检验拓扑信息的可用性。
- 然后进一步根据集群拓扑信息定位检查所有数据盘的可用性，并扫描数据盘上的数据块。
- 最后根据DHT数据分布式路由算法的原理，按照数据在系统中各块硬盘上的分布，恢复出所有数据。

FusionOne Storage集群数据恢复工具，具有以下技术特点：

- 必须在业务停止运行时执行恢复，恢复过程中完整校验所有数据，保证数据一致性。如果遇到数据不一致的情况，可根据选择自动修复数据或跳过不一致的数据。
- 支持按照一定的策略恢复部分数据
- 支持深度恢复模式与一般恢复模式，深度恢复模式下，元数据以及标签数据全部得以保留，一般恢复模式仅支持恢复出数据及元数据。

10.2 硬件可靠性

可用性和可服务性

- 单板硬件采用电信级器件及加工工艺流程，可显著提高系统可靠性。
- 支持热插拔的SAS/SATA/NVMe硬盘。SAS/SATA硬盘支持RAID 0/1/1E/10/5/50/6/60，不同的RAID控制卡支持的RAID级别不同。提供RAID缓存，支持超级电容掉电数据保护。
- 使用SSD后的可靠性远远高于传统机械硬盘，从而能够延长系统运行时间。
- 面板提供UID/Healthy LED指示灯、故障诊断数码管、可触控LCD诊断面板，iBMC Web管理界面提供关键部件指示状态，能够指引技术人员快速找到已经发生

故障或存在故障风险的组件，从而简化维护工作、加快解决问题的速度，并且提高系统可用性。

- 提供iBMC直连管理接口，支持iBMC近端运维，提升运维效率。
- 提供2个热插拔电源模块，支持1+1冗余；提供4个热插拔风扇模块，支持N+1冗余，提升系统整体可用性。
- 板载的BMC集成管理模块（iBMC）能够持续监控系统参数、触发告警，并且采取恢复措施，以便最大限度地避免停机。

11 弹性伸缩

11.1 弹性扩展

11.2 DHT分布式哈希算法

11.3 数据副本在线转换

11.1 弹性扩展

FusionOne Storage块存储的分布式架构具有良好的可扩展性，支持超大容量的存储：

- 扩容存储节点后不需要做大量的数据搬迁，系统可以快速达到负载均衡状态。
- 支持灵活的扩容方式，可以独立扩容硬盘、存储节点，或者同时进行扩容。在扩容计算节点时同步扩容存储空间，扩容后的系统仍旧可以是计算和存储融合。
- 存储带宽和缓存都均匀分布到各个节点上，系统IOPS、吞吐量和缓存随着节点的扩容而线性增加。

FusionOne Storage块存储通过创新的架构把分散的SSD或HDD组织成一个高效的类SAN存储池设备，提供比SAN设备更高的I/O，把性能发挥到了极致。

在线扩展

只需将新节点和原有集群置于同一网络，通过图形控制台将新节点添加到集群中即可。扩展后，新增节点的计算和存储资源会自动立即生效，整个扩展过程都是在线完成，不会影响正在运行的业务。

全局自动负载均衡

FusionOne Storage块存储的DHT机制可以保证上层应用对数据的I/O操作会均匀分布在不同节点的不同硬盘上，不会出现局部的热点，实现全局负载均衡。

第一，系统自动将每个卷的数据块打散存储在不同节点的不同硬盘上，冷热不均的数据会均匀分布在不同的节点上，不会出现集中的热点。

第二，数据分片分配算法保证了主用副本和备用副本在不同节点和不同硬盘上的均匀分布，换句话说，每块硬盘上的主用副本和备副本数量是均匀的。

第三，扩容节点或者故障减容节点时，数据恢复重建算法保证了重建后系统中各节点负载的均衡性。

11.2 DHT 分布式哈希算法

传统文件系统存储采用B/B+树索引方式对文件进行管理，以提高文件的查找访问速度。由于是采用查找法进行数据的访问，当文件个数越多，则查找的性能就越慢，到达一定规模时，查找的时间就无法满足业务的实时性要求。根据传统存储的实现方式，一般索引树会尽量优先放置在高速缓存中，当索引的数据超过高速缓存后，访问的效率问题会变得更加严重。


为了解决海量小文件的访问效率问题，FusionOne Storage采用了业界先进的DHT（动态哈希表）技术，该技术的特点是利用一次哈希计算来定位文件，算法的复杂度为 $O(1)$ ，即使已经存储了海量文件，定位文件的时间永远是固定的，从而大大优化了海量文件的访问性能。

FusionOne Storage采用去中心化方式实现数据存储的管理。DHT分布式哈希算法建立一个虚拟的分布式哈希环，均匀地将整个哈希空间分成数千等分，然后将哈希空间的每一个分区均匀地映射到集群的所有磁盘上，确保每一个磁盘所负责的哈希分片数量是一致的。

数据按对象读写时，会将文件按照切片规则（默认4MB）大小生成每个切片的文件名列表（一般是Bucket+文件名+分片编号），然后将文件分片名通过哈希计算，生成一个哈希后的数值，利用哈希值在DHT表中进行查找，从而定位到该分片的磁盘位置获取文件分片的内容。通过组合每个分片，形成整个文件的最终内容。

从文件的定位过程可以发现，哈希计算和DHT表的查找时间是恒定不变的，不会因为文件数量的增加，而影响效率，从而保证了在海量文件数量的情况下的访问性能。

图 11-1 DHT 分布式哈希



- 通过DHT分布式哈希算法，FusionOne Storage分布式存储管理者可以通过配置信息指定集群数据分布方式（机架级别和服务端级别）。例如服务器级别下，数据默认2副本时，通过DHT将数据的主从副本分别存放在不同服务器的硬盘上，也就意味着当有一台服务器故障时，数据不会丢失。
- 使用DHT分布式哈希算法，数据均衡分布，能够充分利用磁盘的容量和性能，因此读取和写入都更加高效。
- 抗故障性高。由于非中心化设计，不存在特定服务器异常而导致业务暂停。
- 伸缩性好。在扩容或故障时，DHT会自动均衡变化的存储资源，尽量不重构数据以保证业务性能。

11.3 数据副本在线转换

FusionOne Storage提供了2~3副本的存储冗余策略，并实现了在线副本策略转换，在适应应用数据安全性需求，提高存储资源利用率，保护用户存储资源投资方面具有非常好的实际应用意义，例如：

- 根据业务系统不同时期的重要性和数据安全要求变化，可以转换为不同的副本策略，副本数越多，数据安全性越高；
- 存储空间资源不足时，可动态降低相对次要业务系统的副本数，提高存储空间利用率；
- 在线执行副本策略转换，无缝提高业务系统的数据安全保护等级，避免传统设备停机进行数据迁的方式，保证业务连续性。

12 高性能

12.1 负载均衡

12.2 智能缓存

12.1 负载均衡

FusionOne Storage存储系统是一套分布式存储系统，由多个存储节点组成，存储集群中每个存储节点都能够对外提供存储服务。负载均衡及高可用技术，能够在现有的网络结构上扩展网络设备及存储节点的带宽，增加吞吐量及网络处理能力，并提供访问入口高可用，保障系统的可靠性及业务的连续性。

FusionOne Storage系统中，块业务采用多路径实现服务的负载均衡及高可用。由iSCSI组成的IPSAN环境，由于主机和存储通过了光纤交换机或者多块网卡及IP来连接，这样的话，就构成了多对多的关系。主机到存储可以有多条路径可以选择，每个主机到所对应的存储可以经过几条不同的路径。此时多路径的主要功能就是和存储设备一起配合实现故障的切换和恢复、流量的负载均衡以及磁盘的虚拟化。

多路径

多路径是由块业务客户端和存储设备一起配合实现，每个主机可以通过不同的网络路径连接到存储不同存储节点。FusionOne Storage支持块客户端多路径自动切换存储服务的机制，当某个节点或者某条IO路径出现故障时，FusionOne Storage客户端会自动切换到其他正常节点和IO路径，以保证业务的持续可用性。

多路径下支持块业务负载均衡，客户端业务通过不同路径均衡的下发业务，保证整体业务性能达到最优。

高效负载均衡

块业务通过多路径可以实现业务高可用和负载均衡，多路径下的每条路径都是随时可用，保证在故障场景下能很快切换其他路径，极大地降低业务感知时间。

高性能

存储每个节点都可以对外提供可靠的业务，不同节点可以配置或通过客户端分配业务压力，这样可以大大增加分布式存储的优势，提高整集群性能和吞吐量。


快速故障切换

在节点故障的场景下，故障切换能够保证在10s内完成，大大提高业务连续性。

FusionOne Storage系统提供块存储卷的负载均衡及高可用方案，具备高性能、高可靠性等优点，能够在实际生产使用时发挥出存储集群的整体性能。快速的故障切换能够大大缩短节点故障所带来的切换时间，保障业务连续性。

12.2 智能缓存

FusionOne Storage的每个存储节点上配置少量闪存盘，一块闪存盘与多块硬盘组成绑定关系。每块闪存盘可给多块HDD做缓存加速。一般情况下，建议每个存储节点至少配置两块或以上闪存盘。




12.2.1 数据类型感知

FusionOne Storage的智能缓存模块可自动识别存储系统不同类型的数据（数据库、ERP、VDI等），针对不同的数据类型自动采用不同的加速策略，优化缓存资源利用率与业务IO性能。

对于系统元数据、高优先级的数据（如设置了高优先级的桶数据），智能缓存模块不会将其淘汰出闪存，保证IO路径上的元数据访问性能以及较为繁忙业务的数据访问性能。

对于恢复过程产生的数据流量，智能缓存模块同样可以自动识别，这部分数据会透过缓存模块，直接写入硬盘，保证集群不会因为一时的恢复导致缓存资源被临时占用。

图 12-1 数据感知的智能缓存



12.2.2 多级缓存加速

FusionOne Storage的智能缓存模块采用两级缓存技术，第一级缓存为内存缓存，缓存更为频繁访问的数据，加速数据的读取。第二级为闪存缓存，可同时加速数据读写，由于闪存盘的保电特性，当新写入的数据到达每个存储节点，且数据写到闪存盘后，便可立即返回客户端写操作成功。数据进入闪存盘就表示数据已经安全，因此不需要立即刷到对应的硬盘中，存储系统会以异步模式将闪存盘中的数据进行去重和合并处理后刷到后端的硬盘中，即如果对一个数据进行多次修改，则只需将最新修改的数据刷到硬盘中，如果多个数据块是属于一个并且数据在逻辑上是连续的，则可以将这些逻辑上连续的数据写入到物理连续的硬盘上，这样数据被访问时即使未命中缓存，也会因为其在硬盘上的顺序性和连续性而提高数据的访问性能。

12.2.3 分布式缓存

FusionOne Storage块存储缓存和带宽都均匀分布到各个节点节点上。

FusionOne Storage块存储集群内各节点节点的硬盘使用独立的I/O带宽，不存在独立存储系统中大量磁盘共享计算设备和存储设备之间有限带宽的问题。

FusionOne Storage块存储支持将节点部分内存用作读缓存，SSD用作写缓存，数据缓存均匀分布到各个节点上，所有节点的缓存总容量远大于采用外置独立存储的方案。即使采用大容量低成本的SATA硬盘，FusionOne Storage块存储仍然可以发挥很高的I/O性能，整体性能提升1~3倍。

FusionOne Storage块存储支持SSD用作数据缓存，除具备通常的写缓存外，增加热点数据统计和缓存功能，加上其大容量的优势，进一步提升了系统性能。

12.2.4 读缓存

FusionOne Storage使用SSD作为读Cache介质以加速存储访问。FusionOne Storage的读缓存采用分层机制：

第一层为内存Cache，内存Cache采用LRU机制缓存数据；

第二层为SSD Cache，采用热点读机制，系统会统计每个读取的数据，并统计热点访问因子，当达到阈值时，系统会自动缓存数据到SSD中，同时会将长时间未被访问的数据移出SSD。

同时FusionOne Storage支持预读机制，统计读数据的相关性，读取某块数据时自动将相关性高的块读出并缓存到SSD中。

12.2.5 写缓存

FusionOne Storage在收到客户端发送的写IO操作时，会将写IO缓存在SSD缓存后完成本节点写操作。

副本场景：SSD缓存中的内容为IO的完整数据

EC场景：SSD缓存中的内容为数据或者冗余条带

同时，FusionOne Storage会周期将缓存在SSD缓存中的写IO数据批量写入到硬盘，写缓存有一个水位值，未到刷盘周期超过设定水位值也会将缓存中数据写入到硬盘中。

12.2.6 缓存资源回收

数据下盘

新写入闪存盘的数据，会被智能缓存模块刷到后端硬盘上，这个过程称为刷盘。刷到硬盘之后，原来驻留在闪存盘中的数据仍可以提供读命中，不会立即失效。除非智能缓存模块判定其为不经常被访问的冷数据，才会被回收。

数据老化

当闪存盘中的数据达到老化阈值时，会按照LRU来回收最长时间未被访问的缓存数据，以便预留出足够的缓存空间给新业务数据。

12.2.7 大块数据透传

FusionOne Storage的智能缓存模块可根据预设的数据块大小缓存策略来按业务写请求的大小进行是否缓存的决策。默认情况下，当数据块大小大于512KB，并且此次写请求与上次写请求的逻辑地址连续时，即使闪存中有空间也不会写入闪存，而是直接写入硬盘，充分发挥机械硬盘的顺序数据访问性能。

13 安全性

FusionOne Storage总体安全框架分层简要介绍如下：

- 存储设备安全：操作系统加固、补丁管理、Web安全。
- 存储网络安全：平面隔离、通道安全。
- 存储业务安全：存储资源访问控制、认证鉴权、系统防病毒。
- 存储管理安全：管理系统用户安全、密码安全、认证鉴权、日志和告警管理。

13.1 设备安全

13.2 网络安全

13.3 管理&业务安全

13.1 设备安全

FusionOne Storage的设备安全主要从3个方面采取手段，即操作系统加固、安全补丁和Web安全。

操作系统加固主要是通过专门支持的FusionOS操作系统，在内存隔离、内核参数、广播响应、目录权限、账号口令以及审计日志方面都做了安全增强。

安全补丁主要是针对操作系统设计漏洞，FusionOne Storage产品根据操作系统安全补丁和开源软件安全补丁官方的发布情况，结合实际的使用需求，为用户定期提供安全补丁。


Web安全主要是软件的访问控制，包括HTTPS加密访问、防脚本和SQL攻击、请求伪造、敏感信息隐藏以及访问鉴权控制等等。

13.1.1 操作系统安全性（自研 FusionOS 22）

FusionOS 22 是一款基于 Linux 内核的服务器操作系统，支持多CPU（NUMA）架构、多进程、多用户，主要安装在企业级物理服务器、云主机、虚拟机上，可用于大型计算系统和存储系统，也可用于组建大型分布式系统。

FusionOS 22 作为直接运行在硬件（含虚拟化硬件）之上的基础软件，负责管理系统中的所有硬件（含虚拟硬件）资源、软件资源，维护自身的安全性和功能，并为上层服务提供不同级别的支持（包括中间件、管理工具等）。

FusionOS 22 系统由硬件层、内核层、中间件层、应用层构成，还包括各种安全管理界面。系统的整体结构如下：



- **硬件层**
硬件层包含CPU、内存、硬盘、网卡以及其它类型的外设。目前，绝大多数CPU都支持多个特权级，以运行具有不同特权级的不同软件，实现系统不同执行域的隔离。内存包括RAM、NVRAM等类型，磁盘包括机械硬盘、固态硬盘等类型，而网卡和其它外设的类型则更为多样化。这些种类繁多的硬件构成了操作系统硬件兼容性的主要部分。此外，为了保证系统初始状态的完整性，系统往往还配置了TPM芯片，用以在系统启动阶段和运行阶段验证所用的固件、软件、数据的状态。
- **内核层**
操作系统的内核一般运行在CPU的高权限级别，包括内存管理、进程调度、进程间通讯、文件系统、安全访问控制、安全审计、网络协议栈等子系统，以及各类设备驱动程序，是整个系统功能和安全性的基础。
- **中间件层**
内核层提供了基本的功能和服务，但还不能或很难由顶层的应用直接调用，中间件层是二者之间的桥梁，把内核提供的功能做进一步封装，为应用层提供更易使用的接口和服务。中间件层包括各种编程语言的开发库、系统管理所使用的库。
比如，基于业界标准实现的libc库为应用软件在不同平台的平滑移植提供了基础；openssl库则提供了广泛使用的密码学算法功能，避免了应用中相同功能的重复开发，也有利于提高应用软件的安全性。
- **应用层**
应用层包含最终用户使用的众多软件，也包括系统管理员经常使用的各类管理工具。操作系统本身只提供了最基本的服务和典型服务，最终用户可部署自己的业务软件。不同的业务软件实现不同的功能，对下层软件和硬件在性能、稳定性、安全性方面有着不同的需求，这也导致了下层软件的复杂化。

操作系统的安全策略

FusionOS 22 操作系统的安全策略可以从三个层面考虑：安全技术、流程管理、人员管理。如下图所示。



- **安全技术**
主要包括操作系统为保证自身和应用程序的安全性而使用的技术，是实现和评价系统和产品安全性的重点内容。安全技术主要包括操作系统的安全、网络通信的安全以及建立在二者之上的应用安全。
- **流程管理**
主要指的是系统开发、维护过程中所使用的角色定义、规章制度、工作流程、工作日志、审查审计等安全相关问题。
- **人员管理**
主要指参与系统设计、开发、维护、使用的人的安全意识、安全能力、安全培训等因素。

13.1.2 硬件安全

- 集成在服务器上的iBMC管理模块可用来监控系统运行状态，并提供远程管理功能。
- 支持BIOS菜单密码，保证系统启动及系统管理的安全性。
- 支持NC-SI (Network Controller Sideband Interface) 特性，支持管理网口和业务网口复用。NC-SI特性可以通过iBMC智能管理系统或BIOS启用/关闭，NC-SI特性默认关闭。
- 集成业界标准的统一可扩展固件接口 (UEFI) ，可提高设置、配置和更新效率并且简化错误处理流程。
- 支持服务器机箱安全面板，保护服务器的本地数据的安全。
- 支持机箱开盖检测，增强安全性。
- 支持Intel执行禁位 (Execute Disable Bit) 功能，与支持的操作系统联合使用时，可防止某些类型的恶意缓冲溢流攻击。
- 支持Intel CBnT (Converged Boot Guard & Trusted Execution Technology) 融合安全可信启动技术，可基于硬件抵御恶意软件攻击，避免设备上的固件被恶意修改，防止未经授权的启动块的执行；允许应用运行在自己的独立空间中，使其不受系统中运行的其他软件的影响，从而增强安全性。

- 支持基于芯片级可信根的安全启动，具备从硬件可信根开始的逐级校验功能，构筑完整的安全启动链。
- 支持可信平台模块（TPM）和可信密码模块（TCM），可提供高级加密功能，如数字签名及远程验证等。
- 满足NIST SP 800-147B规范中的如下要求：
 - 支持BIOS固件数字签名更新机制，更新时进行数字签名校验，防止非授权BIOS固件的更新。
 - 支持Flash安全保护机制，防止OS下对Flash的非法修改。


13.2 网络安全

网络安全的手段主要是网络安全隔离，减少业务面、存储面和管理面的相互窜扰。

网络介绍

FusionOne Storage分布式存储集群系统网络示意如图13-1。

图 13-1 FusionOne Storage 分布式存储网络示意



- 存储业务网络
用于存储节点和计算节点（业务主机）之间的通信，支持iSCSI/RBD/NFS/CIFS/S3对象接口协议。
- 管理网络
用于存储集群系统的管理维护。
- 存储集群网络
存储集群系统内部存储节点间的通信网络。

说明

存储业务网络和管理网络可以共享网络，此时存储业务网络和管理网络使用同一张物理网卡。

13.3 管理&业务安全

13.3.1 存储管理系统安全

管理系统访问控制

FusionOne Storage管理系统支持基于角色的权限访问控制，并能为相应的角色灵活分配不同的资源权限。管理系统角色支持超级管理员、操作者、查看者三种角色。

- 超级管理员：拥有管理系统的所有权限，可以创建各类角色用户，并为其分配指定资源的权限。
- 操作者：拥有操作资源的权限，如创建、修改、删除。
- 查看者：拥有查看资源的权限，可查看指定的资源。

资源主要分为存储资源、硬件管理、系统配置、监控管理、块存储、数据保护：

- 存储资源：存储的硬盘池、逻辑池等资源。
- 硬件管理：硬盘、节点、网络等硬件资源。
- 系统配置：系统的通用配置、告警配置、集群配置以及License管理等系统资源。
- 监控管理：系统的监控、告警、审计日志、操作日志、任务管理等。
- 块存储：卷管理、网关管理等块存储资源。
- 数据保护：存储数据的异步复制等灾备管理。

管理系统用户安全策略

FusionOne Storage管理系统支持为用户设置登录安全策略，保障用户在使用存储管理系统过程中的系统安全。存储策略包括：

参数	说明	设置
会话超时时间	会话默认超时时间	【默认值】1800秒 【取值范围】60-86400
锁定时间	账号锁定时间，在指定时间内，输入密码错误次数达到设置的次数时，系统锁定该用户	【默认值】1800秒 【取值范围】1-31536000
错误次数	允许连续输入密码错误的次数，在指定时间内，输入密码错误次数达到设置的次数时，系统锁定该用户	【默认值】5次 【取值范围】1-100

参数	说明	设置
用户冻结	冻结用户，被冻结的用户不可登录。分为普通冻结和永久冻结，永久冻结的用户将不可登录，普通冻结的用户会在设置的自动解冻时间后解冻，并恢复登录	【默认值】60s 【取值范围】1-31536000

管理系统密码安全

FusionOne Storage管理系统支持设置强密码复杂度策略，防止暴力破解；管理员账号登录后如果密码太简单，会提示修改密码；密码在存储管理系统中加密存储和传输。具体的密码安全策略如下表所示。

参数	说明	设置
密码有效期	设置密码的有效天数，当密码超过设置的天数时，系统会提示修改密码，请及时修改。	【默认值】90天 【取值范围】1-1000
密码必须包含特殊字符	开启后密码需要包含特殊字符，提高密码安全性。	【默认值】关闭
密码允许包含用户名	开启后密码不允许包含用户名，提高安全性。	【默认值】关闭
首次登录修改密码	开启后首次登录强制修改密码。	【默认值】关闭

存储管理系统鉴权认证

管理系统身份认证包括本地认证、AK/SK认证。

- 本地认证：通过系统本地用户名/密码登录管理系统。
- AK/SK认证：通过与用户绑定的AK/SK认证，用户系统接口（RESTful API）认证。

管理系统日志管理

管理系统日志包括操作日志、系统日志、告警日志。

- 操作日志：管理面的所有操作均有操作日志记录，记录的内容包括：登录IP、级别、事件状态、操作人、事件类型、事件对象、产生时间、结束时间。操作日志支持导出以及备份到服务器，更方便运维与管理。
- 系统日志：收集系统指定节点上所有组件的日志，可选择模块存储引擎、管理系统、操作系统，并提供手工清除的功能。
- 告警日志：系统产生的告警信息

13.3.2 数据服务安全

对象服务身份认证和访问控制

FusionOne Storage对象存储服务支持S3/OSS协议认证。通过配置AK(Access Key)和SK(Secret Access Key)，每一次请求都会进行权限验证，可限制应用服务器对存储资源的访问，保证存储系统的安全性。

块服务身份认证和访问控制

- 身份认证

FusionOne Storage块存储服务iSCSI协议支持CHAP认证。通过配置CHAP (Challenge Handshake Authentication Protocol) 安全性认证，可限制应用服务器对存储资源的访问，保证存储系统的安全性。

- 访问控制

FusionOne Storage块存储支持LUN映射功能。应用服务器主机和LUN通过映射建立访问关系后才能访问LUN对应的存储资源。通过该机制控制存储资源的访问，可有效保证存储系统的安全性。

NAS 服务身份认证和访问控制

- NFS共享采用IP认证权限，支持只读、读写方式访问共享，支持root_squash、all_squash开关配置，满足客户端将root或所有用户映射到匿名用户（即等于nfsnobody用户访问），便于权限控制。
- CIFS共享采用用户认证，支持本地用户本地认证（默认）、AD认证和全局认证。本地用户即存储系统中创建的文件用户，注意不是系统管理员。AD认证支持与AD域对接，满足通用办公场景。支持配置是否允许来宾访问（即无需用户信息即可访问）。

13.3.3 数据存储安全

数据恢复技术

- 临时故障

在一定时间内可以重新上线OSD的故障，如升级维护、重启和掉电等。在故障期间降级存储数据，待故障修复后，自动将降级的数据恢复。提升数据存储的冗余度，降低了数据丢失的风险。

- 永久故障

无法重新上线OSD的故障，如坏盘。在一定时间后，自动剔除故障OSD上的数据，将数据恢复到其他OSD，恢复数据的冗余度，提高数据存储的安全性。

数据校验技术

FusionOne Storage产品提供集群副本间数据扫描的操作，检测副本间数据的一致性，包括元数据校验和深度校验。元数据校验只对元数据信息进行扫描，相对比较快。深度校验不仅对元数据进行扫描，还会对存储的数据进行扫描，相对比较慢。用户可以根据需求进行配置，如果发现有不一致的数据，可以及时人工干预，恢复正确的数据，提高数据存储的安全性。

对象业务数据误删保护

FusionOne Storage对象存储支持在多版本状态下恢复由于误删、误覆盖、误修改等被破坏的数据。开启多版本后，可以通过特定的接口，查看对象的当前版本和所有历史版本，多个版本之间能够进行回滚，用户能够直接将数据回滚到某个时间点的状态，提供完备的数据恢复机制，大大提高了重要数据的安全性。

块业务数据保护

- 卷快照

FusionOne Storage块存储支持卷级的快照功能。通过创建卷快照，或配置定时快照策略，可为卷创建某个时间点的快照，作为卷数据的恢复点。基于指定快照可恢复卷在该快照时间点的数据，从而达到数据保护的目的。

- 卷复制

FusionOne Storage块存储支持卷复制功能。卷复制可以把卷当前时刻数据完全复制到一个新卷中，新卷与原卷数据是独立互不影响的，从而达到数据保护的目

的。

- 卷异步复制

FusionOne Storage块存储支持卷级异步复制功能。异步复制是将当前存储集群的卷数据异步复制到远端集群，通过异地冗余集群提供了数据容灾的相对可靠性和安全性。具体技术原理请参考本文

- 延迟删除

FusionOne Storage块存储支持卷数据延迟删除的回收站功能。删除卷仅是将卷移入回收站，后台基于配置的过期时间来进行卷的数据延迟删除。并且用户可将回收站中的卷恢复，从而可有效避免误删除导致数据丢失的情况，达到数据保护的目的。

14 开放兼容

14.1 存储协议兼容

14.2 虚拟化平台兼容

14.3 OpenStack云管平台

14.4 非OpenStack云管平台

14.5 综合网管平台兼容性

14.1 存储协议兼容

FusionOne Storage产品提供的各种类型存储服务均遵循业界主流的协议和标准。

- 块存储接口：遵循标准的SCSI和iSCSI协议，提供分布式块存储业务。
- 对象接口：遵循Amazon S3协议接口对象接口协议，实现了对Amazon S3对象接口的主要功能覆盖。
- 文件接口：提供标准的NFS、CIFS等文件共享协议，提供文件共享存储资源。

14.2 虚拟化平台兼容

FusionOne Storage针对虚拟化的性能做了大量的垂直优化工作，包括支持VMware VAAI加速、Windows ODX加速及OpenStack KVM平台，能够将快照/克隆操作卸载到存储执行，实现秒级的虚拟机克隆。与业界主流的虚拟化软件平台紧密集成，如VMware vShpere、Microsoft Hyper-V、KVM、Citrix XenServer等。

14.3 OpenStack 云管平台

OpenStack旨在为公共及私有云的建设与管理提供软件的开源项目，是业界开放的云管理平台，覆盖了计算、存储、网络等各个方面。

14.4 非 OpenStack 云管平台

FusionOne Storage通过开放Rest API接口与非标准OpenStack云管平台集成，上层云管平台可以通过REST接口对存储系统资源（比如存储集群资源、存储池、卷等）进行监控管理。

14.5 综合网管平台兼容性

IT运维管理平台在数据中心环境中扮演重要角色。通过IT运维管理软件可以实现对整个IT数据中心的统一管理，并可以快捷地对各类设备的状态进行管理、监控和配置。FusionOne Storage支持标准的SNMP管理协议接口，并提供开放的Rest API接口，实现带外集中接入管理和统一维护。

15 术语

术语	解释
SAN	Storage Area Network，存储区域网络。SAN是可由多台计算机访问的存储设备网络，实现多个计算机使用单个硬盘驱动器，就可以在不同计算机之间共享信息。
NAS	Network Attached Storage，基于标准网络协议实现数据传输的网络存储。
NFS	Network File System，网络文件系统，主要应用在Linux、UNIX环境中。NFS可用于不同类型计算机、操作系统、网络架构和传输协议的环境，提供网络文件远程访问和共享服务。
CIFS	Common Internet File System，网络文件共享系统，主要应用于Internet和Intranet中的Windows主机访问网络中的文件或其他资源。
iSCSI	Internet Small Computer System Interface，Internet小型计算机系统接口。
RBD	RADOS Block Device，分布式块存储服务组件。
IOPS	Input/Output Operations Per Second，用于计算机存储设备性能测试的量测方式，可以视为是每秒的读写次数。
EC	Erasure Code，纠删码。一种数据保护方法，它将数据分割成片段，把冗余数据块扩展、编码，并将其存储在不同的位置，比如磁盘、存储节点或者其它地理位置。
QoS	Quality of Service，服务质量。支持用户有效地使用现有的资源，并在无需扩充资源的前提下，保证关键应用接受的服务是高质量的。配置服务质量意味着用户可以更好地控制资源，减少成本，提高用户的满意度。
AD域	Active Directory，活动目录。Windows下的一种域环境，可以集中管理计算机、服务器、用户等信息。
本地存储	服务器自身携带的磁盘存储。
缓存	缓存就是数据写入的缓冲区。